匿名化完整示例报告：PYML 接口验证

真实 EEG 全部 696 特征与显式人工目标；方法、结果及简短讨论。

匿名化历史示例：仅展示人工目标接口验证，不作为新研究结果。

方法

目的与数据来源

本模板检验主包全部方法在正确输入契约下是否能完成实际拟合、保存任务输出并生成结果报告。真实数据来自两张已转换表：整段 18 行、片段 49 行，各 696 特征，均保留全部列、全部记录和原缺失位置；两表分开，不把记录或窗口当作独立被试。身份依据原生 study.json 中的人工确认映射，整段 6 人、片段 5 人。原始会话属于被试内设计，本模板的人工目标不等于该实验的真实条件。

人工目标和任务契约

二分类沿用已冻结的人工 0/1；三分类在各被试内平衡随机分配 0/1/2。连续回归使用固定种子的正对数正态目标，Poisson 回归使用 1+Poisson(3)的正整数目标。目标不根据 EEG 特征或模型分数选择；标签、数值与生成规则保存于目标字典，不赋予生理、临床或实验条件含义。

窗口回归使用真实 696 列特征及正连续人工目标，但顺序由样本 ID 产生并显著标为 ARTIFICIAL，窗口 2、horizon=1；它不是恢复的真实时间。原生单变量 T01–T05 只消费目标历史，因此使用独立 120 点人工趋势/周期/噪声夹具，不能称为利用了 696 维 EEG 外生输入。H03 使用人工离散符号；H01 使用按训练分区中位数填补并标准化后的真实 696 维输入。H02 在极少、高维真实观测上的预检出现 EM 退化，正式混合发射接口例使用独立 180 点、3 特征的人工 GMM 序列；原始真实数据没有因此被删改，也不把夹具通过当作解决了该真实数据的估计限制。

表 1

任务与实际输入范围

任务	目标/观测	输入与来源	解释范围
二/三分类	人工 0/1 或 0/1/2	18×696、49×696 真实特征	工程分类指标与敏感性
连续/Gamma/Tweedie 回归	人工正连续目标	两张真实全特征表	人工目标误差

任务	目标/观测	输入与来源	解释范围
Poisson 回归	人工正整数目标	两张真实全特征表	计数接口与偏差
窗口神经回归	正连续目标＋人工顺序	真实 696 维；窗口 2	不是真实时序结论
单变量预测	独立人工目标历史	每夹具 120 点；EEG 不作外生变量	固定起点接口
HMM	真实有限值/人工混合/离散符号	H01 真实 696 维；H02 人工 3 维；H03 人工符号	不可跨发射维数比较似然
无监督	不需要因变量	两张真实全特征表	全量描述性输出

注。完整目标、人工顺序和预处理依据均保存在 data/；不得把所有行笼统称为真实科研标签或全合成特征。

划分、预处理与修复

普通表格模型按被试 group 划分，学习型填补和缩放只在训练分区拟合。10 次循环使用预先指定的种子，验证被试可重复出现；它们不是 10 个独立实验，也没有跨全部循环始终独立的最终测试集。窗口与 HMM 由原生 SequencePlan 保留组边界，人工顺序对应的分区按保存的计划固定；预测夹具按人工顺序划分。所有流程只运行开发数据接口，最终 test API 未调用。

上轮 40 项未通过包含两种原因：QDA 默认协方差估计无法在每类约 4–5 个训练观测下直接估计 696 维；C30 原生接口当时缺少按被试分组的内部 OOF 支持。前者改用显式 eigen 求解器与 0.5 协方差收缩，属于兼容参数修订；后者在主包中增加分组内部 CV，并在训练入口传递拥有的组元数据，成员管线在每个内折重新拟合预处理。分类与回归均保存内部折被试审计。RANSAC 的 min_samples 改为训练样本的 0.5，避免默认最小抽样量超过可用记录。修复均另建冻结运行，没有覆写旧失败或旧分数。

算法差异与输出

线性分类器在逻辑损失、间隔、惩罚与求解方式上不同；树的平均集成与逐阶段提升具有不同训练依赖。近邻依靠距离，贝叶斯方法依靠条件分布假设。回归的均值、分位数、鲁棒和分布受限目标不能互相替代（Pedregosa et al., 2011; Breiman, 2001; Scikit-learn developers, n.d.）。外部提升实现保留各自参数与类别处理契约（XGBoost developers, n.d.; LightGBM developers, n.d.;

CatBoost developers, n.d.）。深度模块通过 PyTorch/skorch 适配，HMM 通过 hmmlearn 发射与边界契约；时序适配器遵循固定起点历史（PyTorch contributors, n.d.; Skorch developers, n.d.; Hmmlearn developers, n.d.; Statsmodels developers, n.d.）。

搜索与训练前降维单列为流程方法。搜索最多 2 个候选拟合，退火使用连续 C 范围，其余按固定候选规则；五种训练前降维仅在训练分区将 696 维变为 2 维再接 C01（Bergstra & Bengio, 2012; Optuna contributors, n.d.）。独立降维、聚类及异常检测在真实表全量拟合，不声称留出泛化；PCA、ICA、t-SNE、UMAP 等的表示目标不同，图形分离本身不是统计效应（van der Maaten & Hinton, 2008; UMAP developers, n.d.）。完整逐方法差异及参数见附录。

指标、图表与接续

分类报告 accuracy、balanced accuracy、macro F1 及 AUC：二分类正类 1，三分类采用 OvR 宏平均，分数必须来自真实概率或连续决策输出。回归报告 MAE、RMSE 和适用的 R^2；验证少于 2 个观测或目标恒定时，报告层将 R^2标为不可解释并保留原生值及原因。Poisson 和 Gamma 另从已保存预测计算适用偏差。所有数值按来源、目标、表和评价单位分组，不混排不同任务。

分类特征置换从完整已拟合流程的原始 696 列输入进行，每列每循环 1 次，按验证 balanced accuracy 下降量保存负值和全部排序；10 次种子仅作均值与 SD 描述。原生系数和树不纯度解释另存。向量化批量预测只减少计算开销，不重新训练、不改变定义；与旧逐列实现有数值对照。结果文件落盘并完成任务检查后才提交布尔 PASS；错误分类、警告和冻结清单在独立文件中保存，输入/代码/环境变化拒绝直接接续。

结果

实际覆盖与输入契约

当前实际清单为 326 条方法×目标×表流程，各 10 次，共 3260 个槽位；3254 项通过，6 项未通过，0 项未提交。全部 111 个模型及 5 种搜索、5 种训练前降维均保留在覆盖清单。这里是槽位数，不是包含集成成员、搜索和内部 CV 的真实 fit 调用总数。

表 2

全部目标类型的执行状态

目标/任务	预定	PASS	未通过	未提交
binary	840	840	0	0
multiclass	840	840	0	0
continuous	720	720	0	0
count	20	20	0	0
unsupervised	580	580	0	0
forecast	100	100	0	0
sequence	100	100	0	0
hmm	60	54	6	0

注。不删除失败方法制造覆盖；输入实际维数与来源见 tables/data-contracts.csv。最终 test 调用数为 0。

分类结果：表格与逐模型准确率/AUC 图

以下用预先固定的 C01 展示结果读法，不按分数选择示例：表 1 二分类的 accuracy = 0.533（SD = 0.281），AUC = 0.550（SD = 0.369）；表 2 二分类的 accuracy = 0.489（SD = 0.053），AUC = 0.404（SD = 0.219）；表 1 三分类的 accuracy = 0.333（SD = 0.272），AUC = 0.450（SD = 0.315）；表 2 三分类的 accuracy = 0.377（SD = 0.077），AUC = 0.557（SD = 0.118）。这些数值对应人工标签下的开发验证，不代表真实实验条件的解码能力。

表 3

表 1 的二分类验证结果

模型	次数	accuracy M (SD)	AUC M (SD)	macro F1
model:C01	10	0.533 (0.281)	0.550 (0.369)	0.457

模型	次数	accuracy M (SD)	AUC M (SD)	macro F1
model:C02	10	0.533 (0.281)	0.450 (0.369)	0.483
model:C03	10	0.467 (0.281)	0.600 (0.394)	0.400
model:C04	10	0.500 (0.283)	0.450 (0.369)	0.415
model:C05	10	0.467 (0.281)	0.600 (0.394)	0.400
model:C06	10	0.467 (0.322)	0.500 (0.408)	0.390
model:C07	10	0.500 (0.176)	0.575 (0.334)	0.325
model:C08	10	0.500 (0.283)	0.550 (0.284)	0.440
model:C09	10	0.533 (0.233)	0.550 (0.197)	0.412
model:C10	10	0.367 (0.246)	0.450 (0.438)	0.300
model:C11	10	0.300 (0.292)	0.425 (0.409)	0.250
model:C12	10	0.367 (0.246)	0.450 (0.438)	0.300
model:C13	10	0.333 (0.000)	0.400 (0.394)	0.250
model:C14	10	0.467 (0.281)	0.550 (0.258)	0.398
model:C15	10	0.500 (0.324)	0.575 (0.290)	0.432
model:C16	10	0.333 (0.222)	0.325 (0.290)	0.257
model:C17	10	0.367 (0.189)	0.375 (0.358)	0.282
model:C18	10	0.467 (0.358)	0.550 (0.350)	0.407
model:C19	10	0.500 (0.176)	0.500 (0.000)	0.325
model:C20	10	0.300 (0.189)	0.425 (0.290)	0.215
model:C21	10	0.533 (0.233)	0.400 (0.459)	0.412
model:C22	10	0.500 (0.236)	0.450 (0.497)	0.450
model:C23	10	0.367 (0.105)	0.425 (0.169)	0.265
model:C24	10	0.533 (0.172)	0.500 (0.000)	0.340
model:C25	10	0.500 (0.176)	0.500 (0.000)	0.325
model:C26	10	0.500 (0.176)	0.500 (0.000)	0.325
model:C27	10	0.400 (0.211)	0.300 (0.350)	0.323
model:C28	10	0.500 (0.176)	0.500 (0.000)	0.325
model:C29	10	0.567 (0.316)	0.650 (0.412)	0.515
model:C30	10	0.567 (0.353)	0.475 (0.416)	0.425
model:C31	10	0.400 (0.306)	0.475 (0.432)	0.305
model:N01	10	0.667 (0.272)	0.650 (0.474)	0.615

注。按 ID 排列；图中同时保留不可估计模型。整段每次验证仅 3 行，指标粒度很粗；SD 不是独立样本置信区间。

表 4

表 2 的二分类验证结果

模型	次数	accuracy M (SD)	AUC M (SD)	macro F1
model:C01	10	0.489 (0.053)	0.404 (0.219)	0.362
model:C02	10	0.489 (0.053)	0.360 (0.174)	0.350
model:C03	10	0.459 (0.133)	0.396 (0.239)	0.341
model:C04	10	0.499 (0.063)	0.380 (0.218)	0.369
model:C05	10	0.469 (0.104)	0.388 (0.228)	0.360
model:C06	10	0.469 (0.043)	0.368 (0.193)	0.344
model:C07	10	0.471 (0.093)	0.474 (0.079)	0.330
model:C08	10	0.491 (0.053)	0.520 (0.079)	0.398
model:C09	10	0.489 (0.097)	0.457 (0.155)	0.400
model:C10	10	0.541 (0.066)	0.548 (0.168)	0.430
model:C11	10	0.521 (0.089)	0.390 (0.127)	0.407

模型	次数	accuracy M (SD)	AUC M (SD)	macro F1
model:C12	10	0.541 (0.066)	0.548 (0.168)	0.430
model:C13	10	0.509 (0.118)	0.464 (0.227)	0.406
model:C14	10	0.507 (0.139)	0.504 (0.147)	0.402
model:C15	10	0.501 (0.082)	0.527 (0.098)	0.390
model:C16	10	0.507 (0.147)	0.539 (0.181)	0.446
model:C17	10	0.530 (0.128)	0.452 (0.146)	0.449
model:C18	10	0.477 (0.116)	0.430 (0.179)	0.419
model:C19	10	0.511 (0.023)	0.500 (0.000)	0.338
model:C20	10	0.427 (0.095)	0.381 (0.140)	0.378
model:C21	10	0.489 (0.023)	0.466 (0.155)	0.340
model:C22	10	0.489 (0.071)	0.594 (0.113)	0.373
model:C23	10	0.511 (0.023)	0.500 (0.000)	0.338
model:C24	10	0.511 (0.023)	0.500 (0.000)	0.338
model:C25	10	0.437 (0.178)	0.393 (0.291)	0.402
model:C26	10	0.511 (0.023)	0.500 (0.000)	0.338
model:C27	10	0.569 (0.143)	0.483 (0.249)	0.498
model:C28	10	0.511 (0.023)	0.500 (0.000)	0.338
model:C29	10	0.497 (0.144)	0.397 (0.240)	0.409
model:C30	10	0.532 (0.058)	0.562 (0.245)	0.410
model:C31	10	0.561 (0.133)	0.505 (0.181)	0.485
model:N01	10	0.479 (0.121)	0.461 (0.176)	0.411

注。按 ID 排列；图中同时保留不可估计模型。整段每次验证仅 3 行，指标粒度很粗；SD 不是独立样本置信区间。

表 5

表 1 的三分类验证结果

模型	次数	accuracy M (SD)	AUC M (SD)	macro F1
model:C01	10	0.333 (0.272)	0.450 (0.315)	0.244
model:C02	10	0.367 (0.246)	0.550 (0.334)	0.278
model:C03	10	0.367 (0.189)	0.483 (0.288)	0.261
model:C04	10	0.300 (0.246)	0.567 (0.316)	0.217
model:C05	10	0.367 (0.189)	0.483 (0.288)	0.261
model:C06	10	0.333 (0.222)	0.567 (0.344)	0.239
model:C07	10	0.333 (0.000)	0.483 (0.266)	0.167
model:C08	10	0.433 (0.161)	0.517 (0.232)	0.294
model:C09	10	0.300 (0.105)	0.475 (0.079)	0.172
model:C10	10	0.267 (0.141)	0.583 (0.264)	0.183
model:C11	10	0.267 (0.263)	0.550 (0.261)	0.194
model:C12	10	0.200 (0.172)	0.500 (0.294)	0.133
model:C13	10	0.233 (0.274)	0.508 (0.287)	0.178
model:C14	10	0.433 (0.274)	0.575 (0.206)	0.317
model:C15	10	0.300 (0.189)	0.475 (0.142)	0.183
model:C16	10	0.500 (0.176)	0.558 (0.142)	0.378
model:C17	10	0.267 (0.211)	0.525 (0.249)	0.206
model:C18	10	0.367 (0.189)	0.650 (0.214)	0.283
model:C19	10	0.333 (0.000)	0.500 (0.000)	0.167
model:C20	10	0.300 (0.246)	0.583 (0.226)	0.222
model:C21	10	0.300 (0.246)	0.692 (0.184)	0.200

模型	次数	accuracy M (SD)	AUC M (SD)	macro F1
model:C22	10	0.433 (0.161)	0.400 (0.179)	0.306
model:C23	10	0.333 (0.000)	0.542 (0.090)	0.167
model:C24	10	0.333 (0.000)	0.500 (0.000)	0.167
model:C25	10	0.533 (0.233)	0.750 (0.142)	0.456
model:C26	10	0.333 (0.000)	0.500 (0.000)	0.167
model:C27	10	0.367 (0.189)	0.667 (0.272)	0.261
model:C28	10	0.333 (0.000)	0.500 (0.000)	0.167
model:C29	10	0.433 (0.274)	0.550 (0.324)	0.328
model:C30	10	0.267 (0.141)	0.467 (0.270)	0.150
model:C31	10	0.400 (0.211)	0.600 (0.214)	0.278
model:N01	10	0.233 (0.161)	0.500 (0.261)	0.128

注。按 ID 排列；图中同时保留不可估计模型。整段每次验证仅 3 行，指标粒度很粗；SD 不是独立样本置信区间。

表 6

表 2 的三分类验证结果

模型	次数	accuracy M (SD)	AUC M (SD)	macro F1
model:C01	10	0.377 (0.077)	0.557 (0.118)	0.241
model:C02	10	0.417 (0.063)	0.592 (0.150)	0.256
model:C03	10	0.387 (0.086)	0.592 (0.160)	0.265
model:C04	10	0.427 (0.068)	0.609 (0.161)	0.282
model:C05	10	0.387 (0.072)	0.603 (0.162)	0.263
model:C06	10	0.427 (0.068)	0.590 (0.153)	0.265
model:C07	10	0.317 (0.032)	0.515 (0.130)	0.160
model:C08	10	0.392 (0.175)	0.479 (0.140)	0.257
model:C09	10	0.357 (0.082)	0.475 (0.133)	0.230
model:C10	10	0.337 (0.094)	0.585 (0.162)	0.188
model:C11	10	0.287 (0.082)	0.576 (0.171)	0.189
model:C12	10	0.357 (0.125)	0.598 (0.138)	0.214
model:C13	10	0.357 (0.094)	0.635 (0.122)	0.240
model:C14	10	0.358 (0.073)	0.532 (0.043)	0.233
model:C15	10	0.398 (0.054)	0.542 (0.049)	0.279
model:C16	10	0.306 (0.136)	0.427 (0.147)	0.238
model:C17	10	0.327 (0.103)	0.496 (0.120)	0.212
model:C18	10	0.339 (0.079)	0.516 (0.133)	0.214
model:C19	10	0.317 (0.032)	0.500 (0.000)	0.160
model:C20	10	0.324 (0.086)	0.540 (0.067)	0.220
model:C21	10	0.356 (0.127)	0.565 (0.150)	0.221
model:C22	10	0.354 (0.090)	0.498 (0.162)	0.245
model:C23	10	0.327 (0.041)	0.503 (0.007)	0.164
model:C24	10	0.347 (0.048)	0.500 (0.000)	0.171
model:C25	10	0.381 (0.103)	0.536 (0.156)	0.272
model:C26	10	0.317 (0.032)	0.500 (0.000)	0.160
model:C27	10	0.347 (0.116)	0.532 (0.120)	0.258
model:C28	10	0.317 (0.032)	0.500 (0.000)	0.160
model:C29	10	0.408 (0.063)	0.603 (0.119)	0.275
model:C30	10	0.297 (0.037)	0.520 (0.121)	0.154
model:C31	10	0.410 (0.143)	0.566 (0.135)	0.328

模型	次数	accuracy M (SD)	AUC M (SD)	macro F1
model:N01	10	0.348 (0.057)	0.553 (0.139)	0.198

注。按 ID 排列；图中同时保留不可估计模型。整段每次验证仅 3 行，指标粒度很粗；SD 不是独立样本置信区间。

对应的四张逐模型对比图分别展示两张表的二分类和三分类准确率、AUC，不以表格或单条 ROC 代替跨模型图。人工标签下偶然高分不构成真实解码或临床效度，不据此选择最佳 EEG 模型。完整逐类指标、预测/分数与所有 696 列排序在 JSON 及 CSV 中保留。

表 7

参数搜索接 C01 的实际验证输出

目标	表	方法	次数	accuracy	AUC
binary	1	search:annealing	10	0.500	0.500
binary	1	search:genetic	10	0.533	0.550
binary	1	search:grid	10	0.533	0.550
binary	1	search:random	10	0.533	0.550
binary	1	search:tpe	10	0.533	0.550
binary	2	search:annealing	10	0.489	0.416
binary	2	search:genetic	10	0.509	0.410
binary	2	search:grid	10	0.509	0.400
binary	2	search:random	10	0.509	0.410
binary	2	search:tpe	10	0.509	0.400
multiclass	1	search:annealing	10	0.333	0.467
multiclass	1	search:genetic	10	0.333	0.467
multiclass	1	search:grid	10	0.333	0.500
multiclass	1	search:random	10	0.333	0.467
multiclass	1	search:tpe	10	0.333	0.483
multiclass	2	search:annealing	10	0.377	0.557
multiclass	2	search:genetic	10	0.397	0.554
multiclass	2	search:grid	10	0.397	0.557
multiclass	2	search:random	10	0.397	0.554
multiclass	2	search:tpe	10	0.397	0.555

注。每流程 10 次；搜索与训练前降维分别报告，不能把这些接 C01 的流程当作额外独立分类器。

表 8

训练前降维接 C01 的实际验证输出

目标	表	方法	次数	accuracy	AUC
binary	1	reduction:fast_ica	10	0.500	0.550
binary	1	reduction:gaussian_random_projection	10	0.500	0.450
binary	1	reduction:kernel_pca	10	0.500	0.525

目标	表	方法	次数	accuracy	AUC
binary	1	reduction:pca	10	0.500	0.550
binary	1	reduction:truncated_svd	10	0.500	0.550
binary	2	reduction:fast_ica	10	0.511	0.520
binary	2	reduction:gaussian_random_projection	10	0.469	0.514
binary	2	reduction:kernel_pca	10	0.531	0.488
binary	2	reduction:pca	10	0.511	0.520
binary	2	reduction:truncated_svd	10	0.511	0.520
multiclass	1	reduction:fast_ica	10	0.300	0.517
multiclass	1	reduction:gaussian_random_projection	10	0.300	0.625
multiclass	1	reduction:kernel_pca	10	0.367	0.433
multiclass	1	reduction:pca	10	0.233	0.517
multiclass	1	reduction:truncated_svd	10	0.233	0.517
multiclass	2	reduction:fast_ica	10	0.344	0.577
multiclass	2	reduction:gaussian_random_projection	10	0.357	0.478
multiclass	2	reduction:kernel_pca	10	0.317	0.520
multiclass	2	reduction:pca	10	0.324	0.584
multiclass	2	reduction:truncated_svd	10	0.324	0.584

注。每流程 10 次；搜索与训练前降维分别报告，不能把这些接 C01 的流程当作额外独立分类器。

连续、计数、窗口与预测结果

表 9

连续回归验证指标

表/夹具	模型	次数	MAE	RMSE	R^2
1	model:N02	10	38.275	64.337	-2.718e+07
1	model:R01	10	0.926	1.255	-3489.850
1	model:R02	10	0.926	1.257	-3539.642
1	model:R03	10	0.242	0.268	-4.737
1	model:R04	10	0.242	0.268	-4.737
1	model:R05	10	2.931e+05	3.826e+05	-2.262e+14
1	model:R06	10	7.797	12.296	-7.159e+05
1	model:R07	10	3.034	4.421	-8.163e+04
1	model:R08	10	0.261	0.285	-8.478
1	model:R09	10	16.931	27.580	-4.635e+06
1	model:R10	10	0.226	0.255	-4.143
1	model:R11	10	0.287	0.327	-8.475
1	model:R12	10	0.300	0.329	-12.194
1	model:R13	10	0.290	0.333	-9.969
1	model:R14	10	0.210	0.245	-2.539
1	model:R15	10	0.249	0.283	-7.122
1	model:R16	10	0.235	0.271	-3.990
1	model:R17	10	0.242	0.268	-4.737
1	model:R18	10	0.310	0.348	-9.002
1	model:R19	10	170.806	287.755	-5.458e+08
1	model:R20	10	1.078	1.092	-228.188

表/夹具	模型	次数	MAE	RMSE	R^2
1	model:R22	10	677.342	1172.919	-9.928e+09
1	model:R23	10	0.930	1.273	-3884.973
1	model:R24	10	0.328	0.354	-8.631
1	model:R25	10	0.242	0.268	-4.737
1	model:R26	10	0.248	0.284	-4.320
1	model:R27	10	0.242	0.268	-4.737
1	model:R28	10	0.553	0.723	-847.949
1	model:R29	10	0.269	0.295	-8.148
1	model:R30	10	0.256	0.294	-3.571
1	model:R31	10	0.926	1.255	-3490.276
1	model:R32	10	1.177	1.252	-669.859
1	model:R33	10	1.597	1.836	-3188.397
1	model:R34	10	2.566	4.101	-9.507e+04
1	model:R35	10	0.926	1.255	-3489.850
1	model:R36	10	0.735	0.971	-1885.341
2	model:N02	10	3.076	4.635	-665.039
2	model:R01	10	5.220	8.028	-1445.657
2	model:R02	10	5.188	7.971	-1419.191
2	model:R03	10	0.364	0.439	-0.239
2	model:R04	10	0.364	0.439	-0.239
2	model:R05	10	1.479e+06	1.630e+06	-1.177e+14
2	model:R06	10	7.909	9.886	-1539.608
2	model:R07	10	9.795	15.251	-5011.646
2	model:R08	10	0.352	0.427	-0.166
2	model:R09	10	8.783	13.023	-3740.208
2	model:R10	10	0.429	0.496	-0.630
2	model:R11	10	0.379	0.439	-0.268
2	model:R12	10	0.565	0.668	-2.079
2	model:R13	10	0.530	0.632	-1.883
2	model:R14	10	0.443	0.527	-0.807
2	model:R15	10	0.496	0.577	-1.249
2	model:R16	10	0.423	0.505	-0.652
2	model:R17	10	0.364	0.439	-0.239
2	model:R18	10	0.367	0.441	-0.273
2	model:R19	10	31.517	53.858	-7.179e+04
2	model:R20	10	1.063	1.135	-7.553
2	model:R22	10	6.202e+30	1.961e+31	-3.278e+64
2	model:R23	10	4.837	7.071	-984.278
2	model:R24	10	0.477	0.567	-1.132
2	model:R25	10	0.364	0.439	-0.239
2	model:R26	10	0.410	0.486	-0.531
2	model:R27	10	0.364	0.439	-0.239
2	model:R28	10	2.786	4.225	-368.278
2	model:R29	10	0.385	0.449	-0.308
2	model:R30	10	0.456	0.540	-0.919
2	model:R31	10	5.220	8.028	-1445.620
2	model:R32	10	5.560	7.059	-827.400
2	model:R33	10	5.519	8.321	-1427.571
2	model:R34	10	4.752	8.461	-3040.398
2	model:R35	10	5.220	8.028	-1445.657
2	model:R36	10	1.421	1.834	-44.260

注。样本不足/常数目标的 R²留空说明，不算拟合失败。均值只汇总同一流程；各任务量纲与评价单位不同，不作跨任务总榜。

表 10

正计数回归验证指标

表/夹具	模型	次数	MAE	RMSE	R²
1	model:R21	10	2.687	3.255	-33.599
2	model:R21	10	1.027e+07	1.448e+07	-9.442e+14

注。样本不足/常数目标的 R²留空说明，不算拟合失败。均值只汇总同一流程；各任务量纲与评价单位不同，不作跨任务总榜。

表 11

人工顺序窗口回归验证指标

表/夹具	模型	次数	MAE	RMSE	R²
1	model:N04	10	0.792	0.792	不可估计
1	model:N06	10	1.028	1.028	不可估计
1	model:N07	10	1.494	1.494	不可估计
1	model:N08	10	1.522	1.522	不可估计
1	model:N09	10	0.879	0.879	不可估计
2	model:N04	10	0.825	0.916	-4.071
2	model:N06	10	1.056	1.129	-6.863
2	model:N07	10	2.187	2.291	-41.788
2	model:N08	10	2.192	2.350	-52.976
2	model:N09	10	0.976	1.076	-6.299

注。样本不足/常数目标的 R²留空说明，不算拟合失败。均值只汇总同一流程；各任务量纲与评价单位不同，不作跨任务总榜。

表 12

独立人工目标预测验证指标

表/夹具	模型	次数	MAE	RMSE	R²
1	model:T01	10	0.983	1.195	-1.758
1	model:T02	10	0.141	0.164	0.948
1	model:T03	10	0.669	0.798	-0.230
1	model:T04	10	0.736	0.863	-0.438
1	model:T05	10	0.153	0.183	0.935
2	model:T01	10	1.194	1.385	-2.902
2	model:T02	10	0.132	0.155	0.951
2	model:T03	10	0.696	0.804	-0.316
2	model:T04	10	0.744	0.854	-0.484

表/夹具	模型	次数	MAE	RMSE	R^2
2	model:T05	10	0.139	0.160	0.948

注。样本不足/常数目标的 R^2留空说明，不算拟合失败。均值只汇总同一流程；各任务量纲与评价单位不同，不作跨任务总榜。

连续回归图按表分别比较 MAE、RMSE 和 R^2；窗口和预测各自比较同一输入契约下的误差。计数例另外保存 Poisson 偏差，Gamma 例保存 Gamma 偏差。人工顺序窗口的验证样本可能只有 1 个，R^2因此不可解释；预测的 120 点历史全部是夹具，不能解释为真实脑电时间。

部分接口虽完成有限值输出，但拟合质量明显失稳：表 1 的 model:R05 平均 MAE 为 2.931e+05、R^2为-2.262e+14；表 2 的 model:R05 平均 MAE 为 1.479e+06、R^2为-1.177e+14；表 2 的 model:R22 平均 MAE 为 6.202e+30、R^2为-3.278e+64。这些大误差按原值保留，并不重新标成程序崩溃或用截尾改善分数；极小迭代预算和小样本高维下，PASS 只说明工程检查通过。图采用对称对数坐标同时显示常规值与极端值，不能据本轮选出科研最佳模型。

HMM、无监督输出与未通过诊断

表 13

HMM 实际验证输出

表/夹具	方法	次数	每观测对数似然
1	model:H01	4	-9.724e+04
1	model:H02	10	-0.431
1	model:H03	10	-7.687
2	model:H01	10	-3.331e+05
2	model:H02	10	-0.710
2	model:H03	10	-1.189

注。H01 真实 696 维、H02 人工 3 维、H03 人工离散符号；似然不能跨这些不同观测空间排名。

真实无监督结果保存全部坐标、聚类标签或异常输出。PCA 示例由本轮保存的 696→2 维坐标直接绘制，不把人工标签或未知真实条件加为科研结论。特征排序图仅展示固定示例前 20 列以保持可读性，完整导出保留 696 列。

表 14

全部真实无监督方法的实际输出

方法	表	次数	行数	输出维数	标签种数	-1 数量
model:A01	1	10	18–18	1–1	2–2	3–6
model:A01	2	10	49–49	1–1	2–2	6–14
model:A02	1	10	18–18	1–1	2–2	13–13
model:A02	2	10	49–49	1–1	2–2	29–29
model:A03	1	10	18–18	1–1	1–1	0–0
model:A03	2	10	49–49	1–1	2–2	4–4
model:A04	1	10	18–18	1–1	2–2	1–1
model:A04	2	10	49–49	1–1	2–2	7–7
model:D01	1	10	18–18	2–2	—	—
model:D01	2	10	49–49	2–2	—	—
model:D02	1	10	18–18	2–2	—	—
model:D02	2	10	49–49	2–2	—	—
model:D03	1	10	18–18	2–2	—	—
model:D03	2	10	49–49	2–2	—	—
model:D04	1	10	18–18	2–2	—	—
model:D04	2	10	49–49	2–2	—	—
model:D05	1	10	18–18	2–2	—	—
model:D05	2	10	49–49	2–2	—	—
model:D06	1	10	18–18	2–2	—	—
model:D06	2	10	49–49	2–2	—	—
model:D07	1	10	18–18	2–2	—	—
model:D07	2	10	49–49	2–2	—	—
model:D08	1	10	18–18	2–2	—	—
model:D08	2	10	49–49	2–2	—	—
model:D09	1	10	18–18	2–2	—	—
model:D09	2	10	49–49	2–2	—	—
model:D10	1	10	18–18	2–2	—	—
model:D10	2	10	49–49	2–2	—	—
model:D11	1	10	18–18	2–2	—	—
model:D11	2	10	49–49	2–2	—	—
model:D12	1	10	18–18	2–2	—	—
model:D12	2	10	49–49	2–2	—	—
model:K01	1	10	18–18	1–1	2–2	0–0
model:K01	2	10	49–49	1–1	2–2	0–0
model:K02	1	10	18–18	1–1	2–2	0–0
model:K02	2	10	49–49	1–1	2–2	0–0
model:K03	1	10	18–18	1–1	2–2	0–0
model:K03	2	10	49–49	1–1	2–2	0–0
model:K04	1	10	18–18	1–1	6–6	0–0
model:K04	2	10	49–49	1–1	8–8	0–0
model:K05	1	10	18–18	1–1	4–4	0–0
model:K05	2	10	49–49	1–1	3–3	0–0
model:K06	1	10	18–18	1–1	2–2	0–0
model:K06	2	10	49–49	1–1	2–2	0–0
model:K07	1	10	18–18	1–1	2–2	0–0
model:K07	2	10	49–49	1–1	2–2	0–0
model:K08	1	10	18–18	1–1	2–2	0–0
model:K08	2	10	49–49	1–1	2–2	0–0

方法	表	次数	行数	输出维数	标签种数	-1 数量
model:K09	1	10	18–18	1–1	1–1	18–18
model:K09	2	10	49–49	1–1	1–1	49–49
model:K10	1	10	18–18	1–1	1–1	0–0
model:K10	2	10	49–49	1–1	6–6	4–4
model:K11	1	10	18–18	1–1	2–2	0–0
model:K11	2	10	49–49	1–1	2–2	0–0
model:K12	1	10	18–18	1–1	2–2	0–0
model:K12	2	10	49–49	1–1	2–2	0–0
model:K13	1	10	18–18	1–1	1–1	18–18
model:K13	2	10	49–49	1–1	6–6	7–7

注。范围为 10 次内最小至最大；标签种数包括-1，-1 在聚类通常是噪声、在异常检测按模型编码解释。连续坐标不报告标签种数。坐标和标签逐行保存，非独立验证性能。

表 15

未通过类型与原因

类别	原因	槽位数
data_or_numerical_support	ValueError: transmat_ rows must sum to 1 (got row sums of [0. 1.])	5
data_or_numerical_support	ValueError: transmat_ rows must sum to 1 (got row sums of [1. 0.])	1

注。程序/接口错误、数据或数值支持、依赖与资源限制分别记录；未定义指标不混入失败数。

本轮 H01 若出现转移矩阵行和为 0，是极少观测、696 维发射估计中隐状态未得到有效转移计数的数值退化。它与 QDA 的收缩配置、堆叠的分组接口修复不同；失败被保留为未通过，不靠反复挑种子或强行归一化无依据的概率制造成功。完整逐槽位原因另见 failures.csv。

日志匹配到 1036 条收敛警告。它们是可重复的文本行数，不是独立实验或失败数量；其他警告和原始日志保留。旧 40 项失败记录没有覆盖，本轮 QDA 参数、分组堆叠实现、RANSAC 与 HMM 预处理/夹具变更均在新运行中独立验证。

简短讨论

未来模板的可用范围

本次交付从单一 0/1 例扩展为明确目标字典、真实拟合、任务特定检查、保存输出、图表及报告的完整链条。分组堆叠修复了此前缺失的内部被试隔离能力，协方差收缩和最小样本配置解

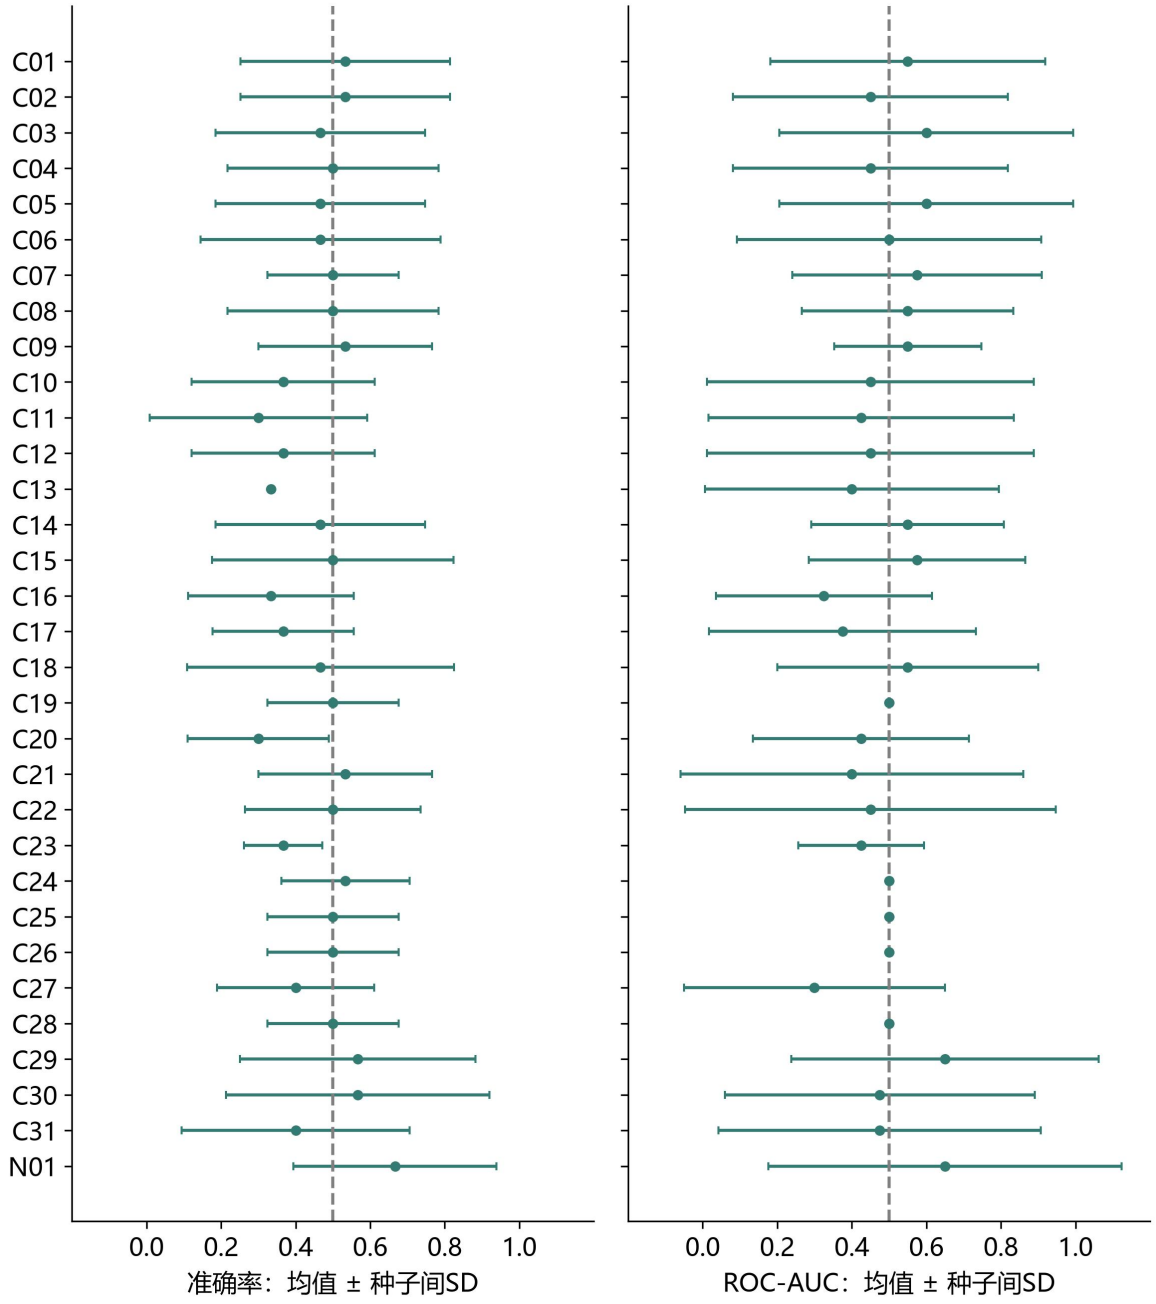
决了已知默认参数的不匹配。数据、参数、状态与解释分开保存，使将来替换真实目标时可以审查来源与边界。

限制与真实研究的区别

人工标签、数值和顺序都不能代替真实实验事实；小样本、高维、极小迭代预算及部分专用夹具限制了结果解释。分类重要性不是生理显著性，窗口不是独立被试，重复种子也不是独立验证。后续真实研究仍需真实目标、合理的独立单位与冻结的评价设计，不能把本模板的开发输出作为最终科学检验（Varoquaux et al., 2017）。

图 1

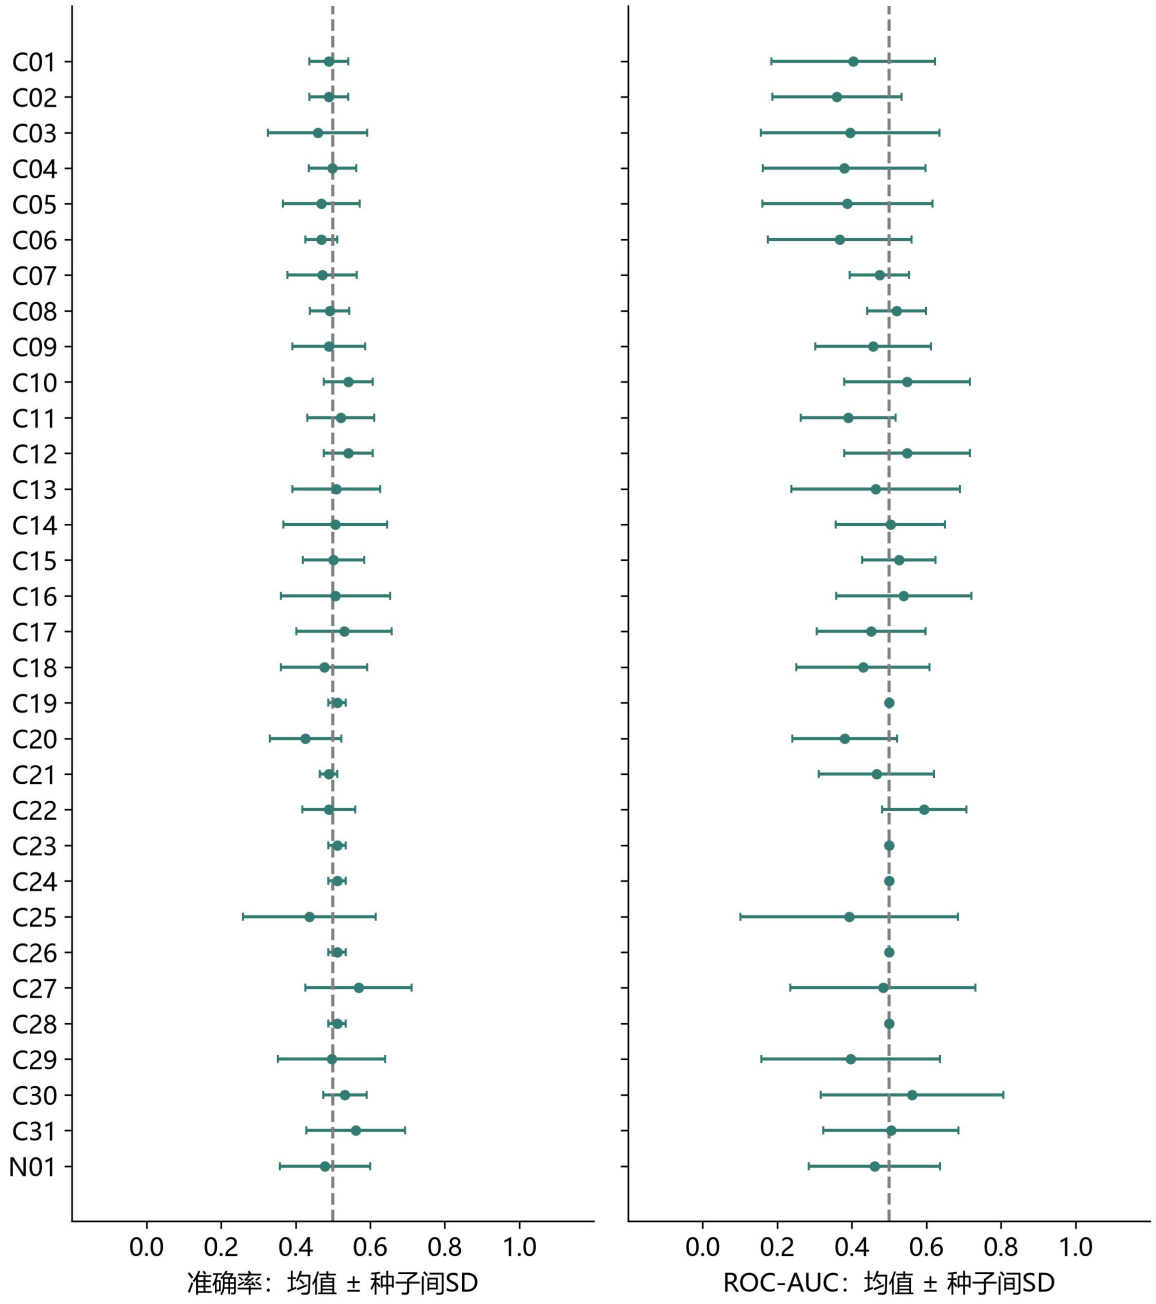
表 1：二分类逐模型准确率与 AUC



注。真实 696 列＋人工目标；按 ID 排列。AUC 为正类 1/三分类 OvR 宏平均。虚线为 accuracy 均匀猜测（.5 或 1/3）及 AUC=.5 参考。误差条为种子间 SD，可超 0–1，非独立样本置信区间。

图 2

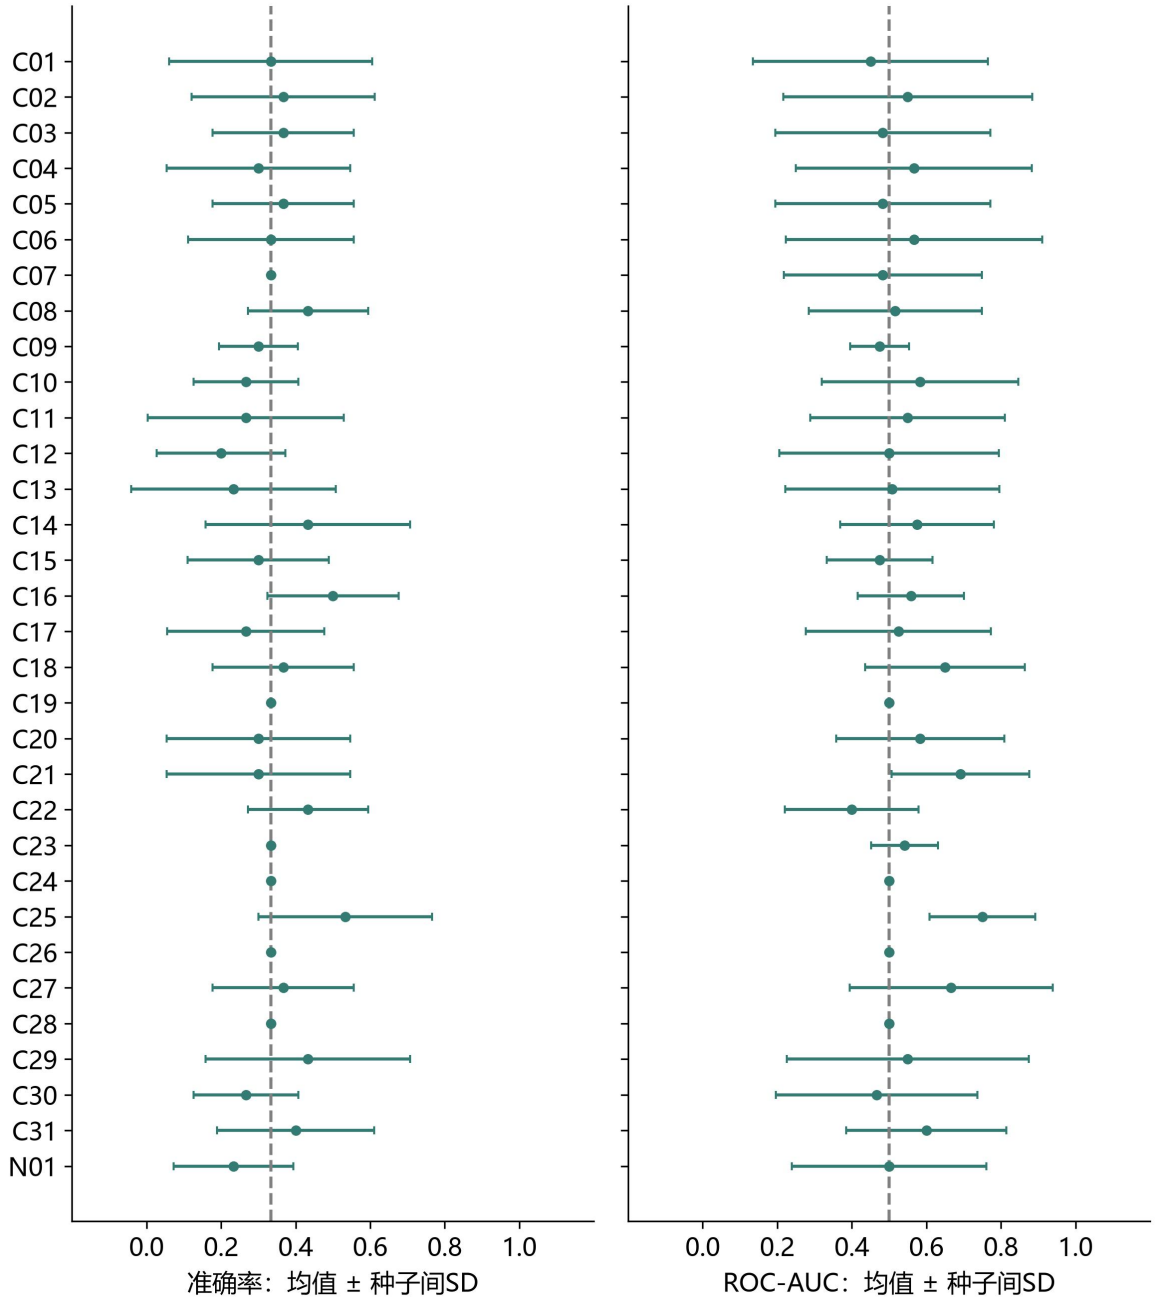
表 2：二分类逐模型准确率与 AUC



注。真实 696 列＋人工目标；按 ID 排列。AUC 为正类 1/三分类 OvR 宏平均。虚线为 accuracy 均匀猜测（.5 或 1/3）及 AUC=.5 参考。误差条为种子间 SD，可超 0–1，非独立样本置信区间。

图 3

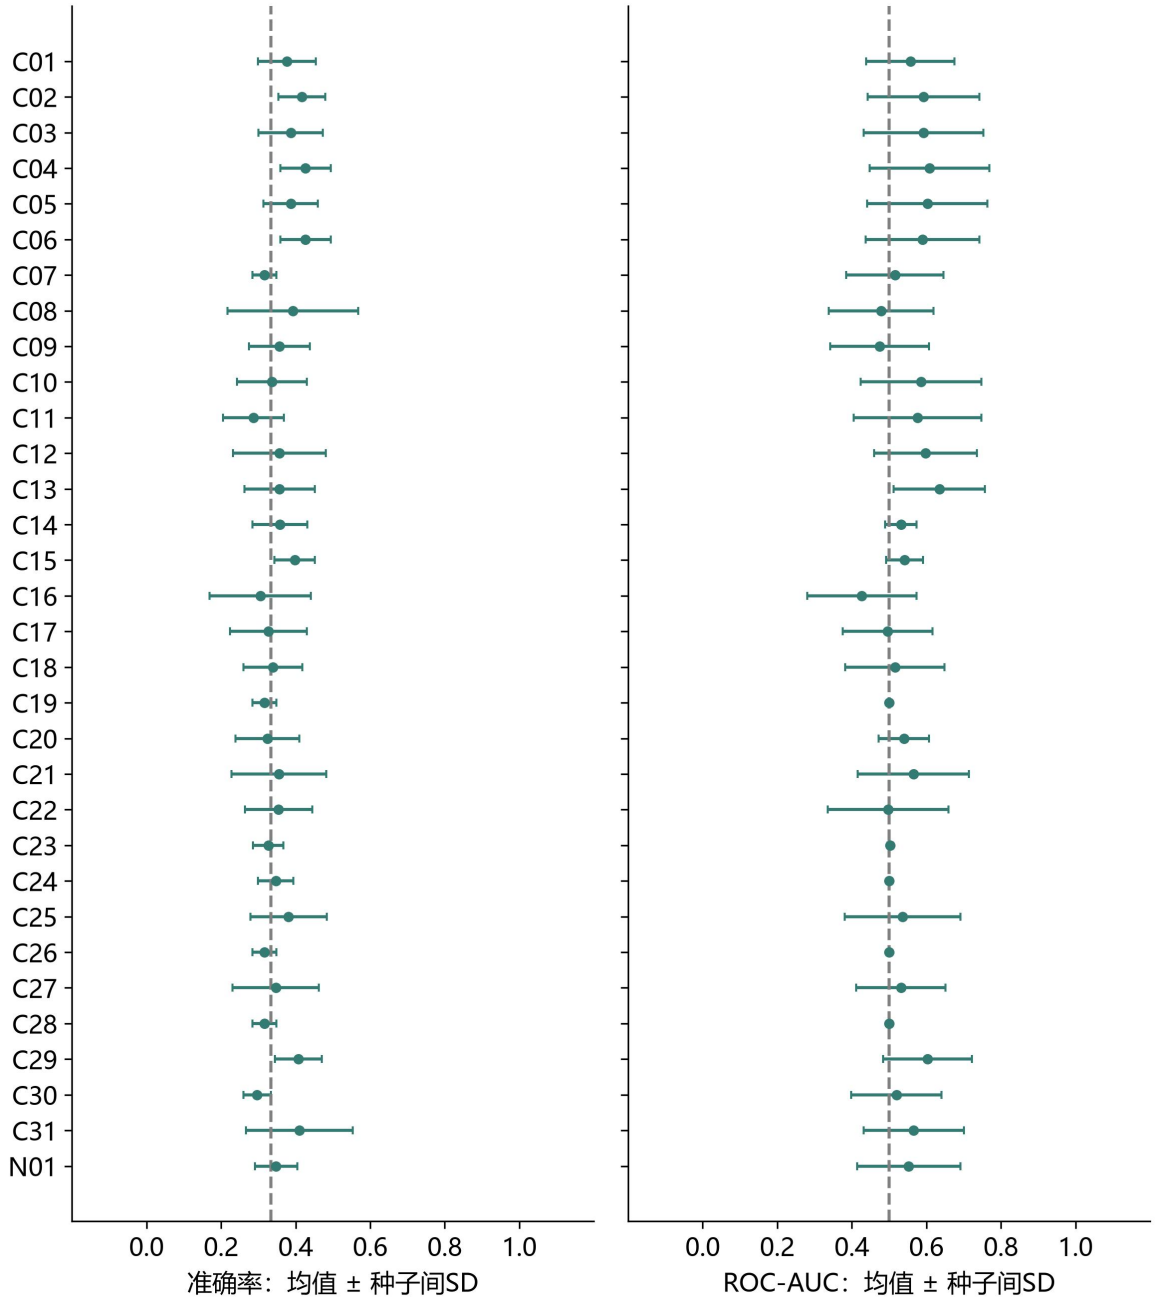
表 1：三分类逐模型准确率与 AUC



注。真实 696 列＋人工目标；按 ID 排列。AUC 为正类 1/三分类 OvR 宏平均。虚线为 accuracy 均匀猜测（.5 或 1/3）及 AUC=.5 参考。误差条为种子间 SD，可超 0–1，非独立样本置信区间。

图 4

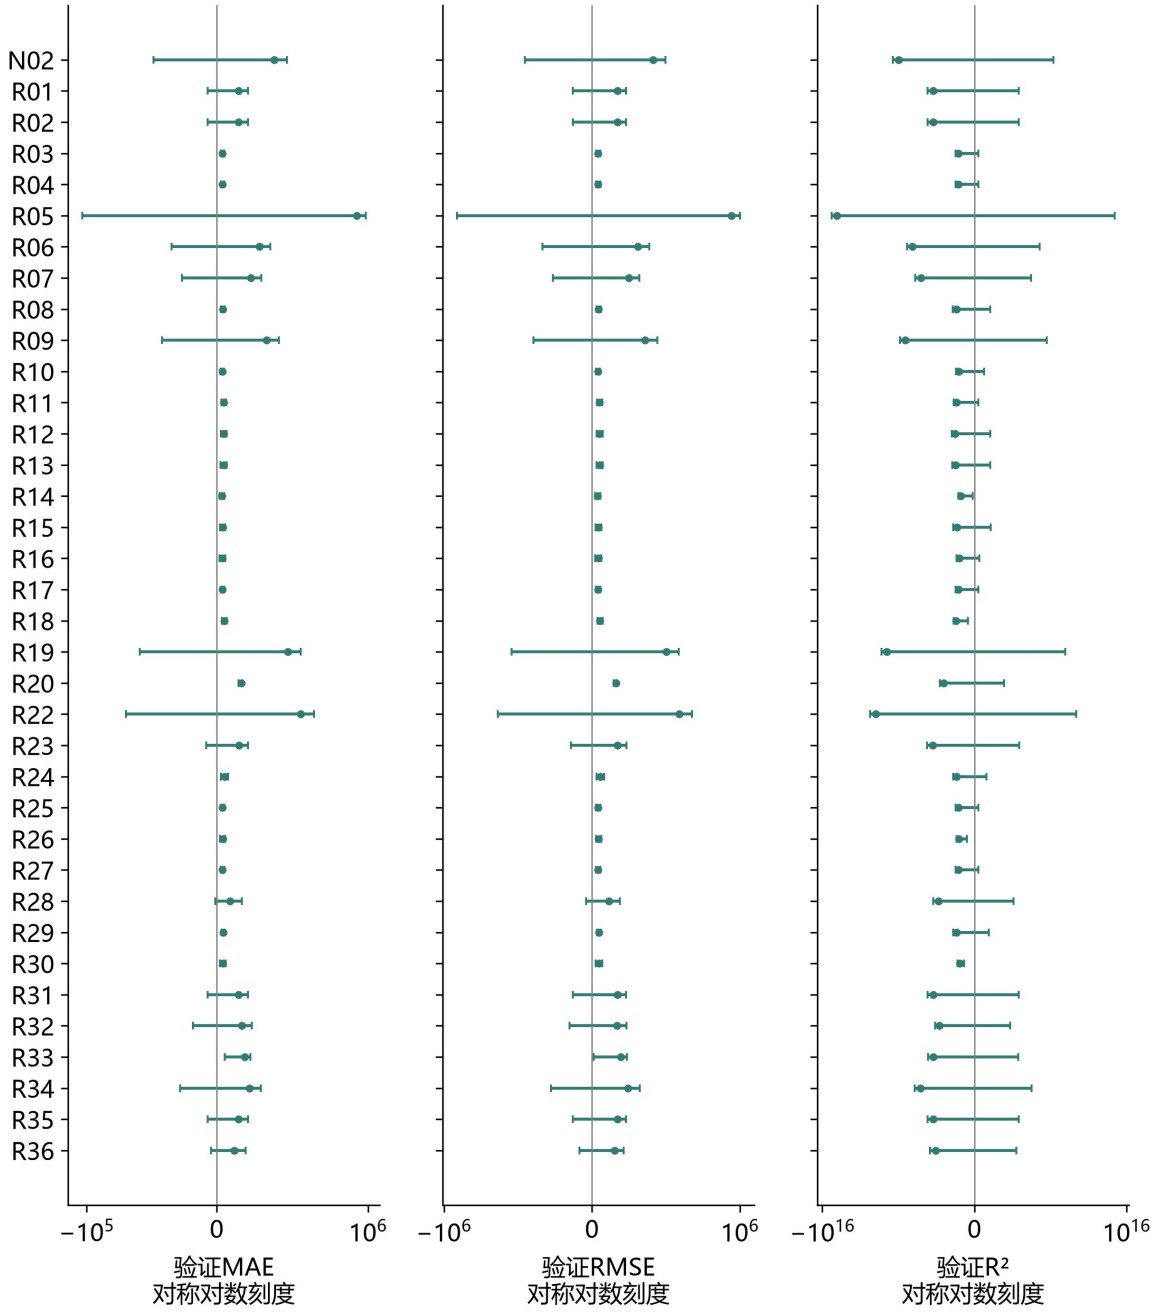
表 2：三分类逐模型准确率与 AUC



注。真实 696 列＋人工目标；按 ID 排列。AUC 为正类 1/三分类 OvR 宏平均。虚线为 accuracy 均匀猜测（.5 或 1/3）及 AUC=.5 参考。误差条为种子间 SD，可超 0–1，非独立样本置信区间。

图 5

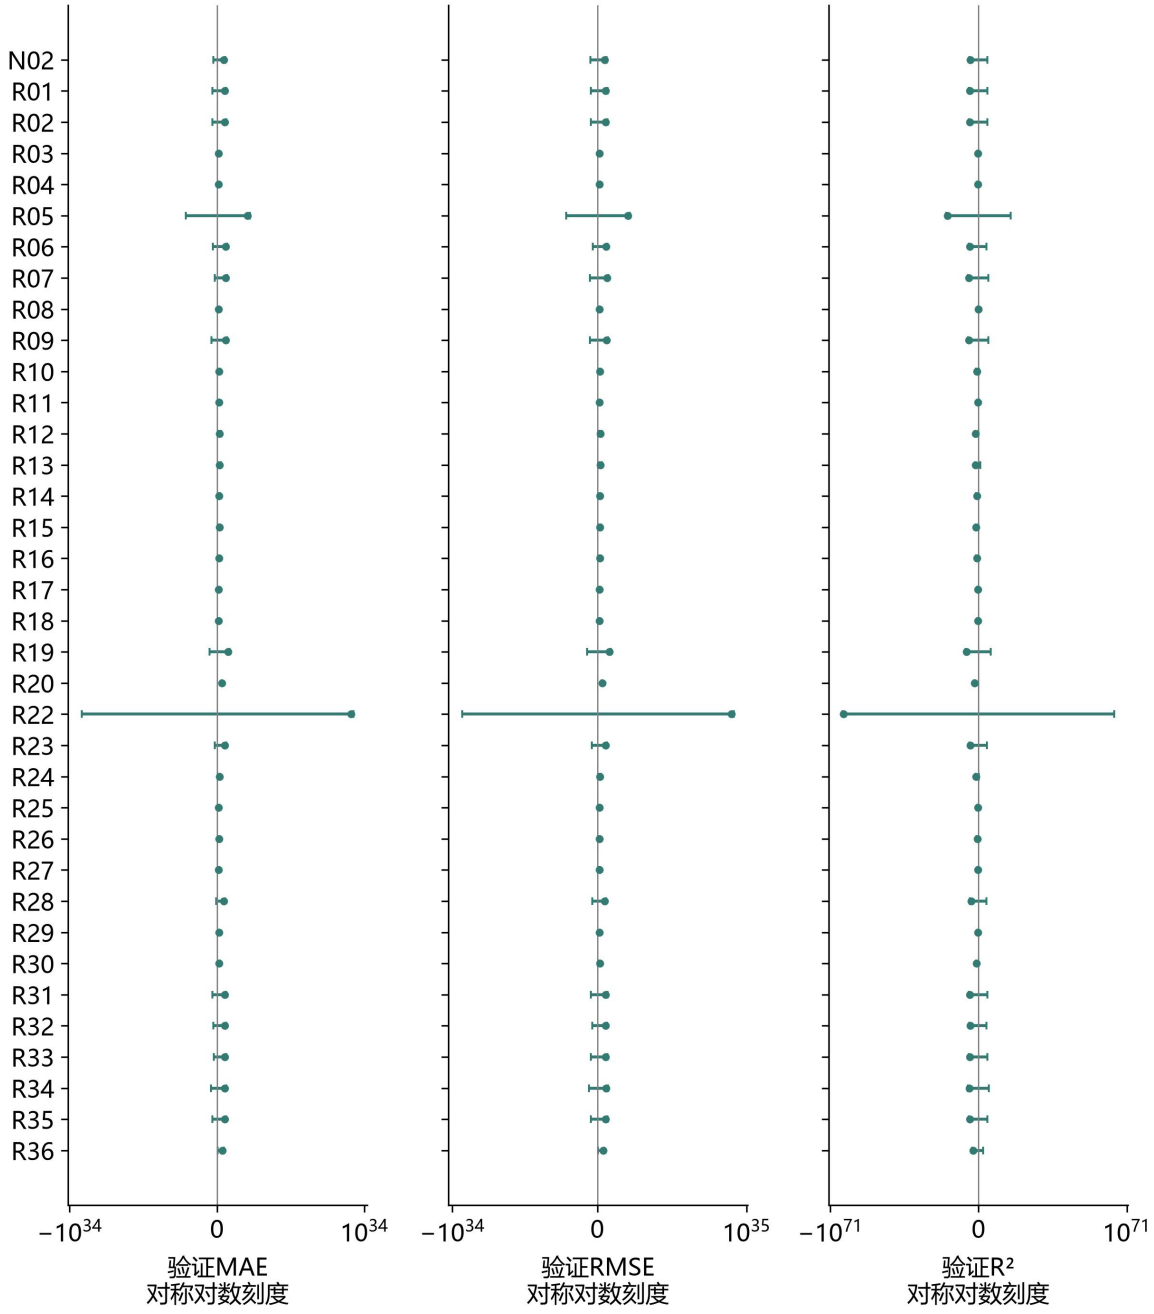
表 1：连续回归模型的验证误差与 R^2



注。同一表内使用固定正连续人工目标；按 ID 排列。误差条为种子间 SD，可越过指标取值界限；对称对数刻度保留极端值、零和负 R^2，$|x| \le 1$ 为线性区。不可解释的 R^2留空。

图 6

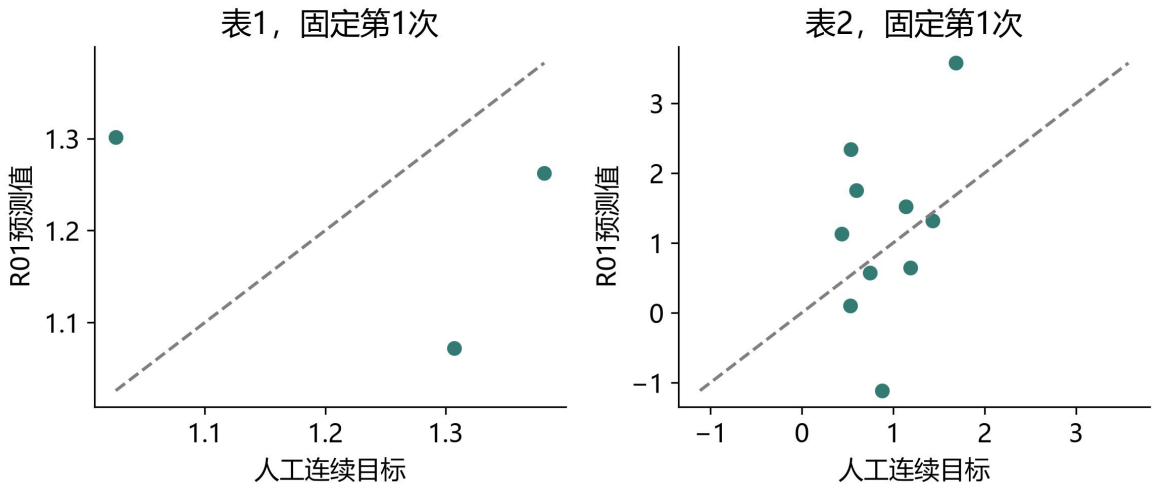
表 2：连续回归模型的验证误差与 R^2



注。同一表内使用固定正连续人工目标；按 ID 排列。误差条为种子间 SD，可越过指标取值界限；对称对数刻度保留极端值、零和负 R^2，$|x| \le 1$ 为线性区。不可解释的 R^2 留空。

图 7

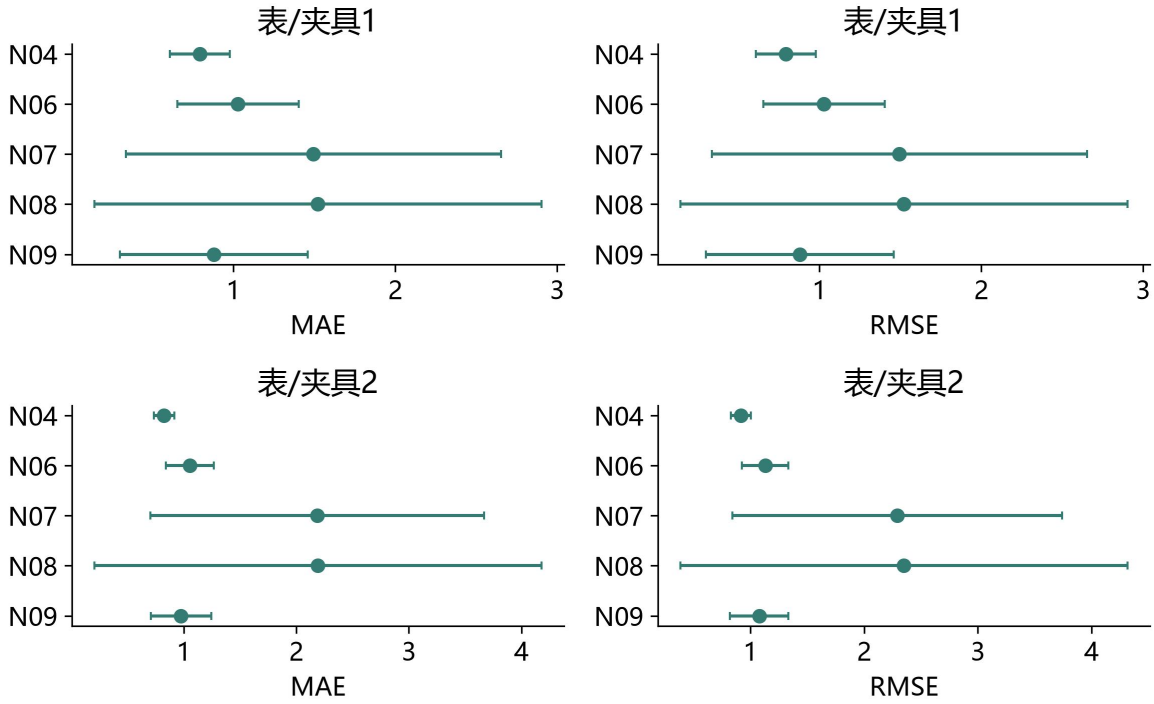
连续回归固定模型的预测—目标图



注。预先固定 R01 第 1 次，不按分数选例；对应完整验证记录。小样本和人工目标下不作生理解释。

图 8

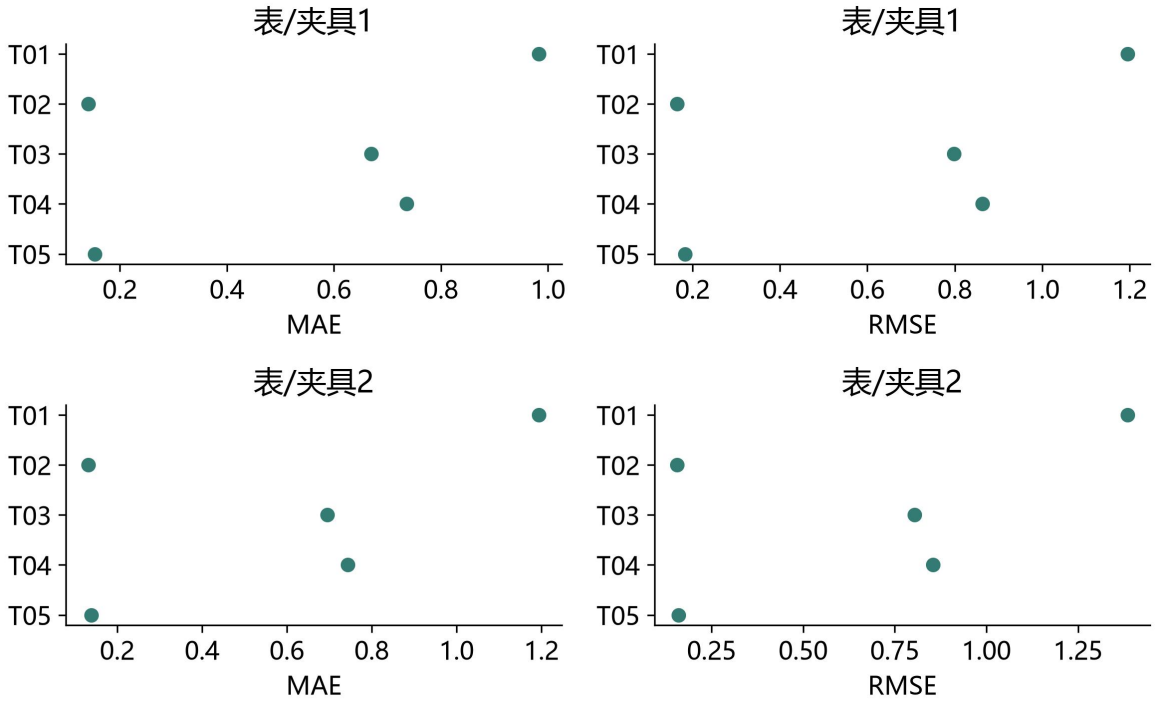
人工顺序窗口回归的误差对比



注。仅比较同一来源与评价单位的方法；窗口和人工顺序不是真实实验时间，预测适配器仅消费人工目标历史。

图 9

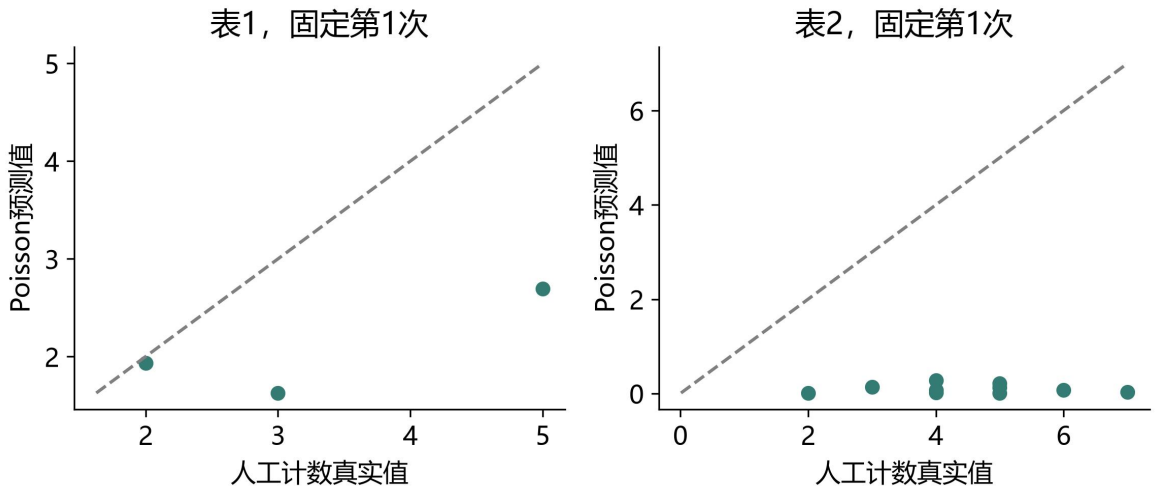
独立人工目标序列预测的误差对比



注。仅比较同一来源与评价单位的方法；窗口和人工顺序不是真实实验时间，预测适配器仅消费人工目标历史。

图 10

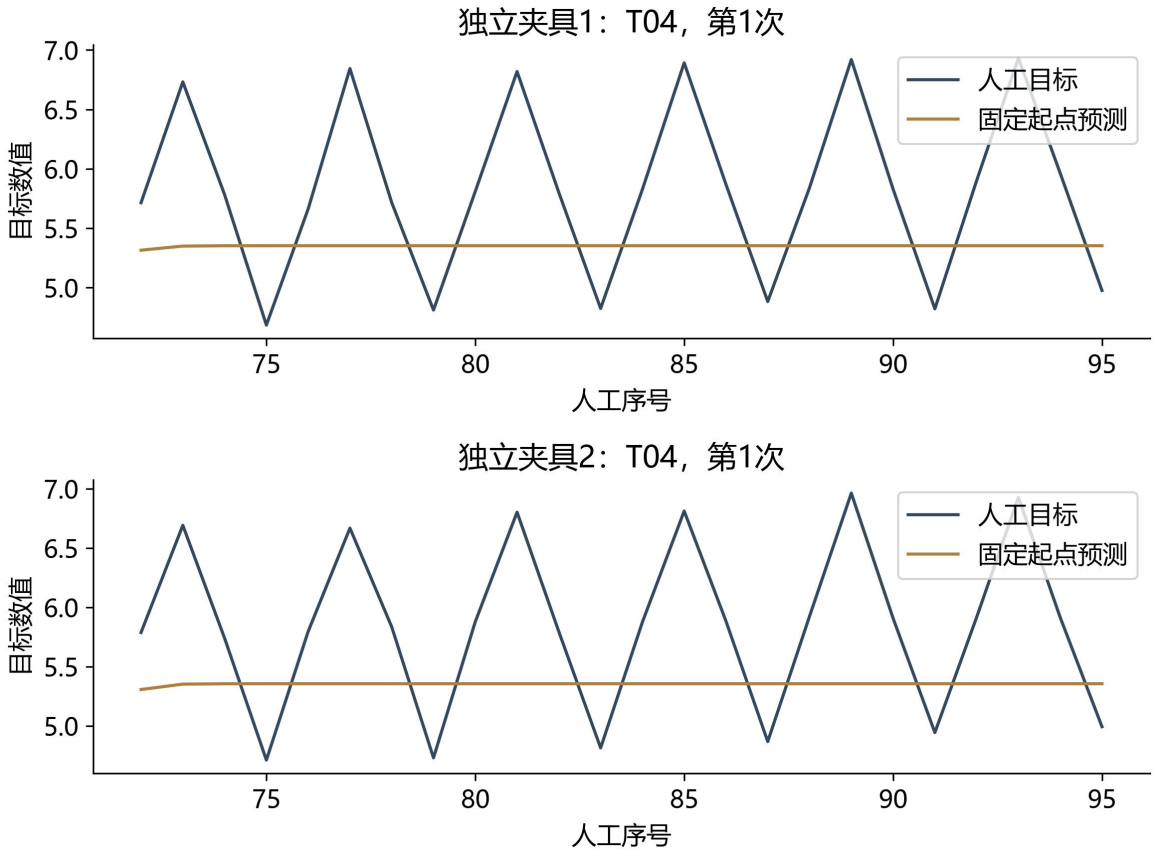
人工正计数目标的固定示例预测



注。计数为 1+Poisson(3)的工程目标，非实际事件数；偏差指标及完整结果另附。

图 11

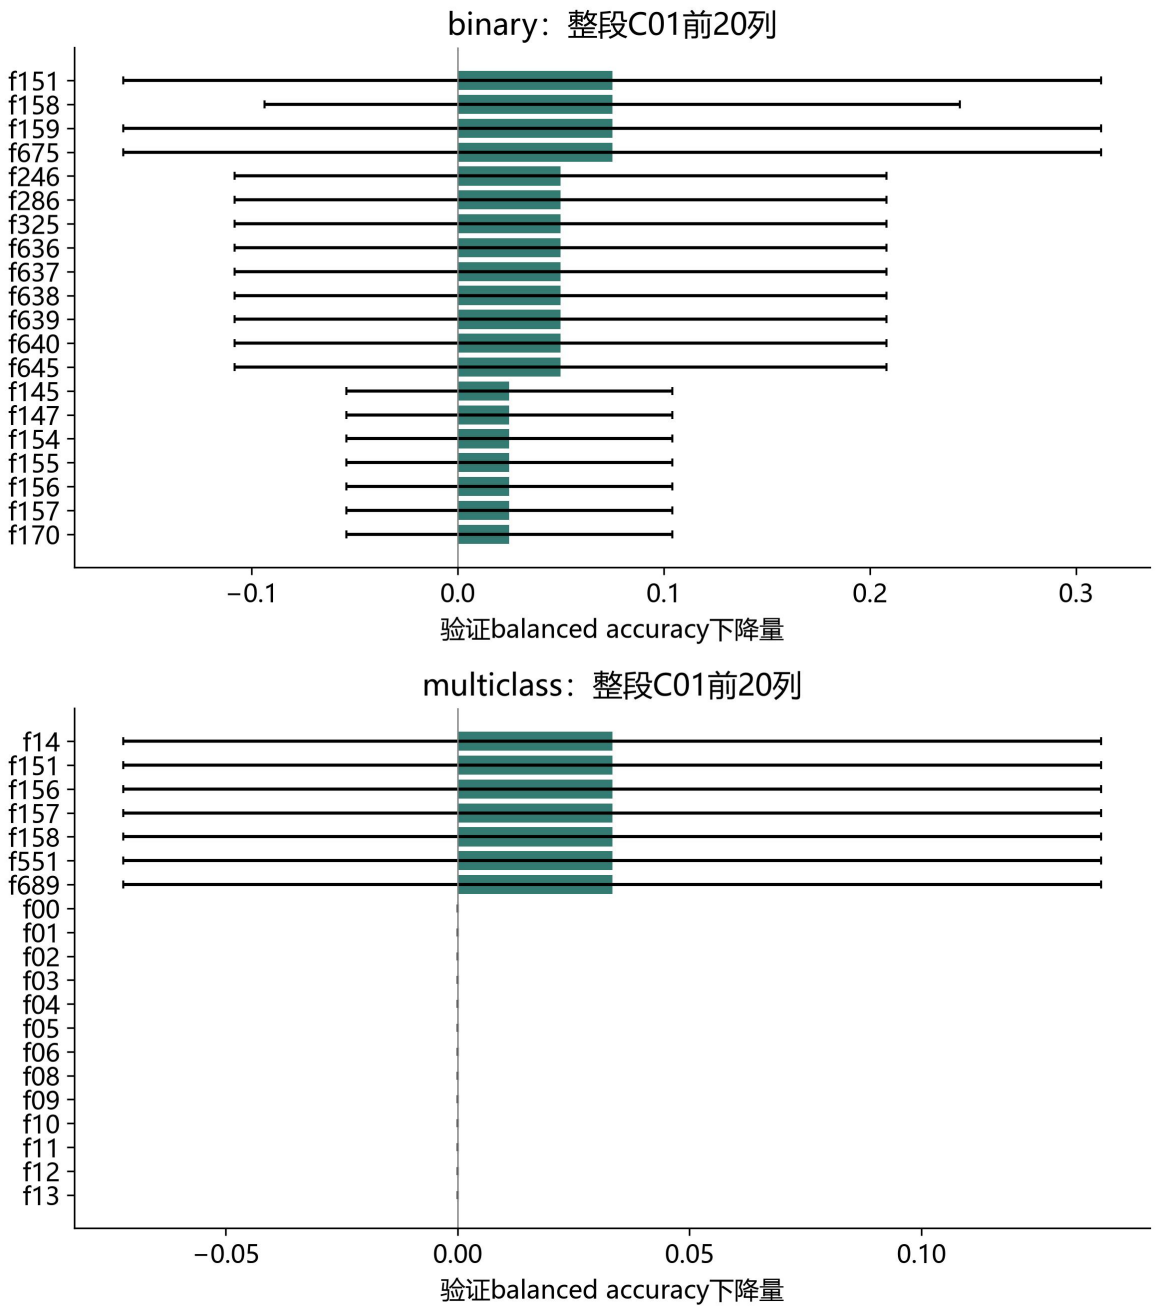
ARIMA 固定示例的人工目标序列预测



注。不使用验证目标更新历史；顺序与目标为独立夹具，不是真实 EEG 时间。

图 12

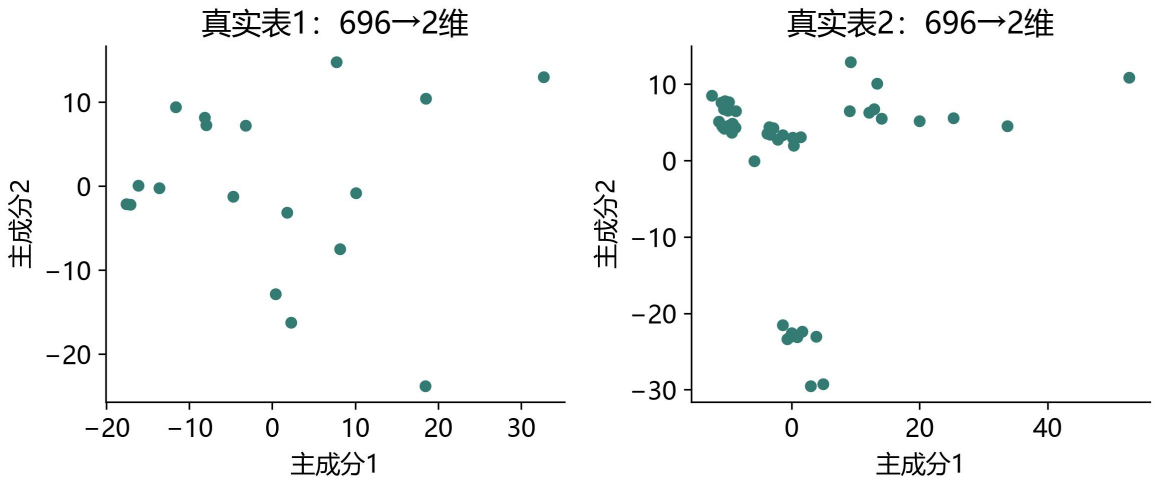
二分类与三分类固定模型的真实输入特征敏感性



注。完整 696 列排序及原始特征映射另附；目标为人工，负值保留，不作脑区或因果解释。

图 13

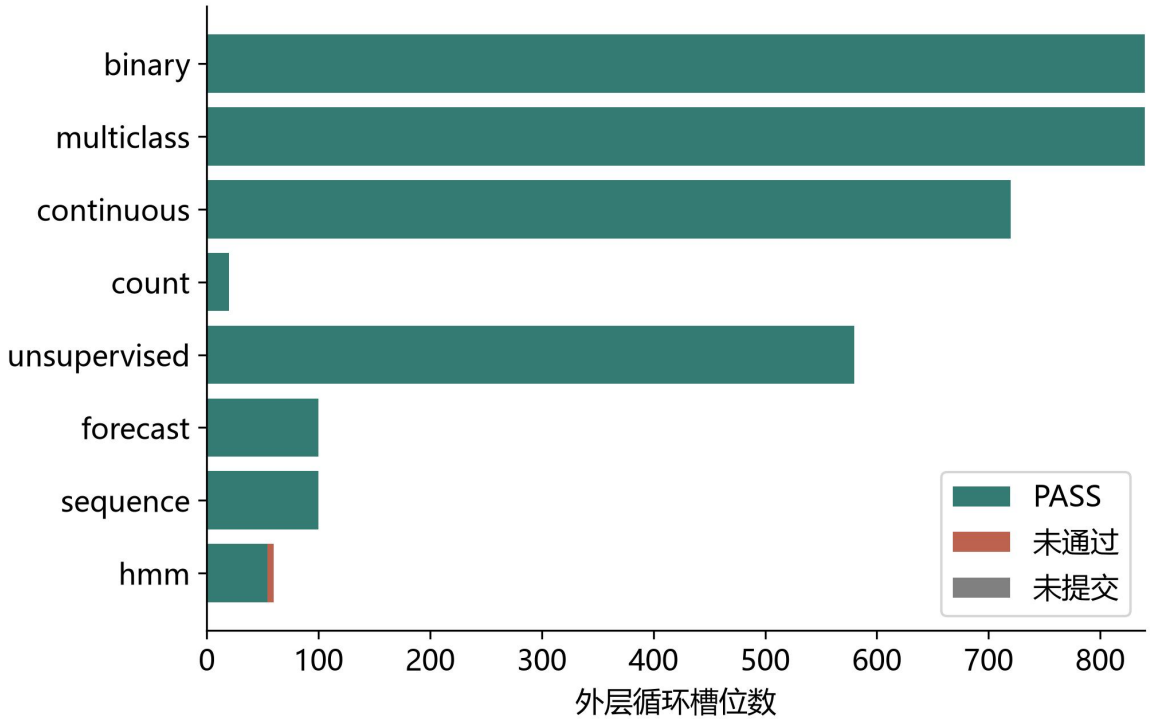
真实全部特征的独立 PCA 描述图



注。未使用人工目标；两表分别全量拟合，非独立验证，不把视觉分离解释为实验条件效应。

图 14

全任务实际执行覆盖



注。方法×目标类型×表×循环计数，保留失败和未提交，不以图中覆盖量代替效度。

参考文献

Bergstra, J., & Bengio, Y. (2012). Random search for hyper-parameter optimization. *Journal of Machine Learning Research, 13*, 281–305. https://jmlr.org/papers/v13/bergstra12a.html

Breiman, L. (2001). Random forests. *Machine Learning, 45*, 5–32. https://doi.org/10.1023/A:1010933404324

CatBoost developers. (n.d.). *How training is performed*. CatBoost documentation. Retrieved November 1, 2026, from https://catboost.ai/docs/en/concepts/algorithm-main-stages

Hmmlearn developers. (n.d.). *Tutorial*. Hmmlearn documentation. Retrieved November 1, 2026, from https://hmmlearn.readthedocs.io/en/stable/tutorial.html

LightGBM developers. (n.d.). *Features*. LightGBM documentation. Retrieved November 1, 2026, from https://lightgbm.readthedocs.io/en/stable/Features.html

Optuna contributors. (n.d.). *optuna.samplers.TPESampler*. Optuna documentation. Retrieved November 1, 2026, from https://optuna.readthedocs.io/en/stable/reference/samplers/generated/optuna.samplers.TPESampler.html

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830. https://jmlr.org/papers/v12/pedregosa11a.html

PyTorch contributors. (n.d.). *torch.nn*. PyTorch 2.14 documentation. Retrieved November 1, 2026, from https://docs.pytorch.org/docs/2.14/nn.html

Scikit-learn developers. (n.d.). *User guide*. Scikit-learn documentation. Retrieved November 1, 2026, from https://scikit-learn.org/stable/user_guide.html

Skorch developers. (n.d.). *NeuralNetRegressor*. Skorch documentation. Retrieved November 1, 2026, from https://skorch.readthedocs.io/en/stable/regressor.html

Statsmodels developers. (n.d.). *Time series analysis tsa*. Statsmodels documentation. Retrieved November 1, 2026, from https://www.statsmodels.org/stable/tsa.html

UMAP developers. (n.d.). *How UMAP works*. UMAP documentation. Retrieved November 1, 2026, from https://umap-learn.readthedocs.io/en/latest/how_umap_works.html

van der Maaten, L., & Hinton, G. (2008). Visualizing data using t-SNE. *Journal of Machine Learning Research, 9*, 2579–2605. https://jmlr.org/papers/v9/vandermaaten08a.html

Varoquaux, G., Raamana, P. R., Engemann, D. A., Hoyos-Idrobo, A., Schwartz, Y., & Thirion, B. (2017). Assessing and tuning brain decoders: Cross-validation, caveats, and guidelines. *NeuroImage, 145*, 166–179. https://doi.org/10.1016/j.neuroimage.2016.10.038

XGBoost developers. (n.d.). *Introduction to boosted trees*. XGBoost documentation. Retrieved November 1, 2026, from https://xgboost.readthedocs.io/en/stable/tutorials/model.html

附录：全部方法差异、参数与本轮通过情况

模型

表 A1

模型差异与状态

方法	机制、配置与契约	PASS/预定
model:C01 分类 · LogisticRegression	以逻辑损失拟合线性类别边界；可给出类别概率，区别于最小二乘分类。 {"max_iter": 10, "n_jobs": 1} binary; multiclass	40/40
model:C02 分类 · RidgeClassifier	将类别编码后作 L2 惩罚最小二乘；线性边界，通常无原生概率输出。 {"max_iter": 10} binary; multiclass	40/40
model:C03 分类 · SGDClassifier	随机梯度优化线性分类目标；具体损失决定间隔或概率含义，学习率影响收敛。 {"max_iter": 10, "n_jobs": 1} binary; multiclass	40/40
model:C04 分类 · PassiveAggressiveClassifier	对满足间隔的样本保持参数，对违例样本作受约束更新；适合在线线性分类。 {"max_iter": 10, "n_jobs": 1} binary; multiclass	40/40
model:C05 分类 · Perceptron	依据误分类更新线性权重；不同于逻辑回归的概率损失，无概率模型。 {"max_iter": 10, "n_jobs": 1} binary; multiclass	40/40
model:C06 分类 · LinearSVC	优化线性大间隔分类目标；区别于核 SVC，不显式构造非线性核边界。 {"max_iter": 10} binary; multiclass	40/40
model:C07 分类 · SVC	核支持向量分类，可学习非线性边界；C 与核参数共同控制复杂度。 {"max_iter": 10} binary; multiclass	40/40
model:C08 分类 · KNeighborsClassifier	由近邻类别投票；局部、非参数，距离尺度及邻居数决定结果。 {"n_neighbors": 3, "n_jobs": 1} binary; multiclass	40/40
model:C09 分类 · GaussianNB	假定给定类别后特征独立且各特征服从高斯分布；适于连续输入。 {} binary; multiclass	40/40

方法	机制、配置与契约	PASS/预定
model:C10 分类 · MultinomialNB	基于非负计数/频率的多项式朴素贝叶斯；数值转为非负不自动满足计数解释。 {} binary; multiclass	40/40
model:C11 分类 · BernoulliNB	建模二值特征出现与未出现；与多项式模型的计数解释不同。 {} binary; multiclass	40/40
model:C12 分类 · ComplementNB	用类别补集统计量构建权重；面向非负、常见于不平衡文本计数。 {} binary; multiclass	40/40
model:C13 分类 · CategoricalNB	按每个特征的离散类别概率建模；需要整数类别编码及合法取值范围。 {} binary; multiclass	40/40
model:C14 分类 · DecisionTreeClassifier	递归选择特征阈值以降低节点不纯度/损失；可解释路径，但深树容易过拟合。 {"max_depth": 3} binary; multiclass	40/40
model:C15 分类 · ExtraTreeClassifier	在候选特征上随机选阈值形成单树；比常规最优阈值树引入更多随机性。 {"max_depth": 3} binary; multiclass	40/40
model:C16 分类 · RandomForestClassifier	聚合随机特征子集下训练的多棵树；主要以平均/投票降低单树方差。 {"n_estimators": 10, "max_depth": 3, "n_jobs": 1} binary; multiclass	40/40
model:C17 分类 · ExtraTreesClassifier	聚合随机阈值树；与随机森林的区别主要在切分阈值随机化及抽样默认策略。 {"n_estimators": 10, "max_depth": 3, "n_jobs": 1} binary; multiclass	40/40
model:C18 分类 · GradientBoostingClassifier	按当前损失梯度逐阶段增加树；依赖前序模型，区别于独立树的平均。 {"n_estimators": 10, "max_depth": 3} binary; multiclass	40/40
model:C19 分类 · HistGradientBoostingClassifier	先将连续特征分箱再进行梯度提升；区别于逐候选值精确搜索的树提升。 {"max_iter": 10, "max_depth": 3} binary; multiclass	40/40

方法	机制、配置与契约	PASS/预定
model:C20 分类 · AdaBoostClassifier	逐阶段调整样本权重或基学习器权重；困难/异常样本可产生较大影响。 {"n_estimators": 10} binary; multiclass	40/40
model:C21 分类 · MLPClassifier	以多层前馈非线性网络拟合目标；分类与回归损失不同，需控制缩放与训练轮数。 {"max_iter": 10, "batch_size": 16, "hidden_layer_sizes": [8]} binary; multiclass	40/40
model:C22 分类 · LinearDiscriminantAnalysis	假定类别条件高斯且共享协方差，得到线性判别；监督投影维度至多类别数减一。 {"n_components": 1} binary; multiclass	40/40
model:C23 分类 · QuadraticDiscriminantAnalysis	每类估计独立协方差而形成二次边界；小样本下协方差估计更不稳定。 {"solver": "eigen", "shrinkage": 0.5} binary; multiclass	40/40
model:C24 分类 · GaussianProcessClassifier	用核定义潜在函数先验并作分类近似推断；区别于仅寻找间隔的 SVM。 {"max_iter_predict": 10, "n_jobs": 1} binary; multiclass	40/40
model:R01 回归 · LinearRegression	以残差平方和拟合条件均值；无正则惩罚，受共线性和离群点影响。 {"n_jobs": 1} continuous	20/20
model:R02 回归 · Ridge	平方损失加 L2 惩罚；收缩相关特征系数，一般不使其精确归零。 {"max_iter": 10} continuous	20/20
model:R03 回归 · Lasso	平方损失加 L1 惩罚；可产生稀疏系数，尺度与正则强度影响选择。 {"max_iter": 10} continuous	20/20
model:R04 回归 · ElasticNet	结合 L1 与 L2 惩罚；在稀疏性与相关特征共同收缩之间折中。 {"max_iter": 10} continuous	20/20
model:R05 回归 · SGDRegressor	用随机梯度求解线性回归目标；区别在求解及可选损失，不自动产生非线性关系。 {"max_iter": 10} continuous	20/20
model:R06 回归 · PassiveAggressiveRegressor	对超出容忍区间的误差作在线受约束更新；依赖尺度与正则控制。 {"max_iter": 10} continuous	20/20

方法	机制、配置与契约	PASS/预定
model:R07 回归 · HuberRegressor	小残差采用平方损失，大残差采用线性损失；降低大残差的影响。 {"max_iter": 10} continuous	20/20
model:R08 回归 · QuantileRegressor	最小化分位数损失，估计指定条件分位数；不能直接解释为条件均值。 {} continuous	20/20
model:R09 回归 · LinearSVR	线性支持向量回归，在 epsilon 容忍区间外惩罚误差；不同于普通平方损失。 {"max_iter": 10} continuous	20/20
model:R10 回归 · SVR	用核构建非线性 epsilon 支持向量回归；距离尺度与核宽度重要。 {"max_iter": 10} continuous	20/20
model:R11 回归 · KNeighborsRegressor	以近邻目标的局部平均/加权平均预测；缺少全局参数方程。 {"n_neighbors": 3, "n_jobs": 1} continuous	20/20
model:R12 回归 · DecisionTreeRegressor	递归选择特征阈值以降低节点不纯度/损失；可解释路径，但深树容易过拟合。 {"max_depth": 3} continuous	20/20
model:R13 回归 · ExtraTreeRegressor	在候选特征上随机选阈值形成单树；比常规最优阈值树引入更多随机性。 {"max_depth": 3} continuous	20/20
model:R14 回归 · RandomForestRegressor	聚合随机特征子集下训练的多棵树；主要以平均/投票降低单树方差。 {"n_estimators": 10, "max_depth": 3, "n_jobs": 1} continuous	20/20
model:R15 回归 · ExtraTreesRegressor	聚合随机阈值树；与随机森林的区别主要在切分阈值随机化及抽样默认策略。 {"n_estimators": 10, "max_depth": 3, "n_jobs": 1} continuous	20/20
model:R16 回归 · GradientBoostingRegressor	按当前损失梯度逐阶段增加树；依赖前序模型，区别于独立树的平均。 {"n_estimators": 10, "max_depth": 3} continuous	20/20
model:R17 回归 · HistGradientBoostingRegressor	先将连续特征分箱再进行梯度提升；区别于逐候选值精确搜索的树提升。 {"max_iter": 10, "max_depth": 3} continuous	20/20

方法	机制、配置与契约	PASS/预定
model:R18 回归 · AdaBoostRegressor	逐阶段调整样本权重或基学习器权重；困难/异常样本可产生较大影响。 {"n_estimators": 10} continuous	20/20
model:R19 回归 · MLPRegressor	以多层前馈非线性网络拟合目标；分类与回归损失不同，需控制缩放与训练轮数。 {"max_iter": 10, "batch_size": 16, "hidden_layer_sizes": [8]} continuous	20/20
model:R20 回归 · GaussianProcessRegressor	核定义函数先验并进行高斯过程回归；区间来自模型假设，不是接口 PASS 的含义。 {} continuous	20/20
model:R21 回归 · PoissonRegressor	使用 Poisson 偏差与对数链接；目标非负，科研解释需要适当计数/均值方差结构。 {"max_iter": 10} count	20/20
model:R22 回归 · GammaRegressor	Gamma 偏差与对数链接；目标严格为正，区别于 Poisson 的方差函数。 {"max_iter": 10} continuous	20/20
model:R23 回归 · TweedieRegressor	用 power 指定均值—方差幂关系；默认 power 与实际目标尺度共同决定含义。 {"max_iter": 10} continuous	20/20
model:K01 聚类 · KMeans	最小化样本到质心的平方距离；需预设簇数，偏好欧氏紧凑簇。 {"max_iter": 10, "n_clusters": 2, "n_init": 1} unsupervised	20/20
model:K02 聚类 · MiniBatchKMeans	用小批量近似更新质心；牺牲部分精确优化换取可扩展性。 {"max_iter": 10, "n_clusters": 2, "n_init": 1, "batch_size": 16} unsupervised	20/20
model:K03 聚类 · BisectingKMeans	递归二分簇形成层次划分；区别于 KMeans 直接同时更新全部质心。 {"max_iter": 10, "n_clusters": 2, "n_init": 1} unsupervised	20/20
model:K04 聚类 · AffinityPropagation	通过相似度消息传递选择代表点；簇数由偏好参数和数据共同决定。 {"max_iter": 10} unsupervised	20/20

方法	机制、配置与契约	PASS/预定
model:K05 聚类 · MeanShift	沿核密度梯度寻找模态；不预设簇数，带宽决定合并尺度。 {"max_iter": 10, "n_jobs": 1} unsupervised	20/20
model:K06 聚类 · Birch	以聚类特征树压缩样本再聚类；阈值决定子簇粒度与内存。 {"n_clusters": 2} unsupervised	20/20
model:K07 聚类 · SpectralClustering	先对相似图作谱嵌入再划分；可处理非凸结构，通常无原生新样本预测。 {"n_clusters": 2, "n_components": 2, "n_neighbors": 3, "n_init": 1, "n_jobs": 1} unsupervised	20/20
model:K08 聚类 · AgglomerativeClustering	从单点逐级合并形成层次结构；链接准则决定簇间距离，无原生新样本预测。 {"n_clusters": 2} unsupervised	20/20
model:K09 聚类 · DBSCAN	用固定邻域密度连接核心点并标记噪声；无需预设簇数，密度尺度需适配。 {"n_jobs": 1} unsupervised	20/20
model:K10 聚类 · OPTICS	构造可达距离排序表达多尺度密度结构；区别于单一邻域尺度的 DBSCAN。 {"n_jobs": 1} unsupervised	20/20
model:D01 降维 · PCA	中心化后寻找最大方差正交方向；不使用目标标签，不等同于生理信号源分离。 {"n_components": 2} unsupervised	20/20
model:D02 降维 · IncrementalPCA	分批近似估计主成分；区别于一次性完整矩阵分解。 {"n_components": 2, "batch_size": 16} unsupervised	20/20
model:D03 降维 · KernelPCA	在核空间提取主成分；非线性映射依赖核设置，默认核不一定非线性。 {"max_iter": 10, "n_components": 2, "n_jobs": 1} unsupervised	20/20
model:D04 降维 · TruncatedSVD	对未强制中心化的矩阵作截断奇异值分解；适合稀疏表示，区别于中心化 PCA。 {"n_iter": 10, "n_components": 2} unsupervised	20/20

方法	机制、配置与契约	PASS/预定
model:D05 降维 · FastICA	通过非高斯性等准则寻找统计独立成分；独立性假设强于不相关性。 {"max_iter": 10, "n_components": 2} unsupervised	20/20
model:D06 降维 · NMF	在非负约束下分解为基与系数；加性成分与 PCA 有符号正交成分不同。 {"max_iter": 10, "n_components": 2} unsupervised	20/20
model:D07 降维 · FactorAnalysis	用潜在线性因子和特征特异噪声解释协方差；区别于 PCA 直接最大化总方差。 {"max_iter": 10, "n_components": 2} unsupervised	20/20
model:D08 降维 · Isomap	以近邻图最短路径近似流形测地距离后嵌入；图连通性影响表示。 {"max_iter": 10, "n_components": 2, "n_neighbors": 3, "n_jobs": 1} unsupervised	20/20
model:D09 降维 · LocallyLinearEmbedding	保留局部线性重建权重生成嵌入；对邻居数和局部几何敏感。 {"max_iter": 10, "n_components": 2, "n_neighbors": 3, "n_jobs": 1} unsupervised	20/20
model:D10 降维 · TSNE	匹配高低维邻域概率以可视化局部结构；本适配器无新样本 transform，不能据图推断条件效应。 {"max_iter": 250, "n_components": 2, "perplexity": 5, "n_jobs": 1} unsupervised	20/20
model:A01 异常检测 · IsolationForest	随机切分隔离样本，以平均路径长度表征异常；阈值依赖污染比例设置。 {"n_estimators": 10, "n_jobs": 1} unsupervised	20/20
model:A02 异常检测 · OneClassSVM	在核空间估计正常样本支持域；nu 与核宽度决定边界和异常比例约束。 {"max_iter": 10} unsupervised	20/20
model:A03 异常检测 · LocalOutlierFactor	将局部密度与邻域密度比较；默认 novelty=False 用于已拟合样本，不能混作新样本检测。 {"n_neighbors": 3, "n_jobs": 1} unsupervised	20/20
model:A04 异常检测 · EllipticEnvelope	用鲁棒位置/协方差拟合椭圆正常域；适用于近似高斯椭圆分布。 {} unsupervised	20/20

方法	机制、配置与契约	PASS/预定
model:C25 分类 · XGBoost	正则化梯度提升树实现；其优化与树控制参数不同于随机森林的独立树平均。 {"n_estimators": 10, "max_depth": 3, "n_jobs": 1} binary; multiclass	40/40
model:C26 分类 · LightGBM	直方图提升树、通常按叶扩展；分箱和叶复杂度控制区别于其他提升实现。 {"n_estimators": 10, "max_depth": 3, "n_jobs": 1} binary; multiclass	40/40
model:C27 分类 · CatBoost	支持类别特征处理及有序提升等机制的提升树库；本次数值夹具未验证类别优势。 {"iterations": 10, "depth": 3, "thread_count": 1} binary; multiclass	40/40
model:R24 回归 · XGBoost	正则化梯度提升树实现；其优化与树控制参数不同于随机森林的独立树平均。 {"n_estimators": 10, "max_depth": 3, "n_jobs": 1} continuous	20/20
model:R25 回归 · LightGBM	直方图提升树、通常按叶扩展；分箱和叶复杂度控制区别于其他提升实现。 {"n_estimators": 10, "max_depth": 3, "n_jobs": 1} continuous	20/20
model:R26 回归 · CatBoost	支持类别特征处理及有序提升等机制的提升树库；本次数值夹具未验证类别优势。 {"iterations": 10, "depth": 3, "thread_count": 1} continuous	20/20
model:C28 分类 · DummyClassifier	忽略输入关联，按预设常数/频率策略预测；提供基线而非学习信号。 {} binary; multiclass	40/40
model:C29 分类 · VotingClassifier	组合多个基学习器的投票或数值平均；不训练负责组合的第二层模型。 {"n_jobs": 1, "cv": 2, "members": ["C01", "C14"], "member_parameters": {"C14": {"max_depth": 3}}} binary; multiclass	40/40

方法	机制、配置与契约	PASS/预定
model:C30 分类 · StackingClassifier	用基学习器的交叉验证输出训练第二层模型；区别于直接投票，需防止元学习泄漏。 {"n_jobs": 1, "cv": 2, "members": ["C01", "C14"], "member_parameters": {"C14": {"max_depth": 3}}} binary; multiclass	40/40
model:C31 分类 · BaggingClassifier	在重采样子集上拟合基学习器并聚合；区别于逐阶段纠正前序误差的提升。 {"n_estimators": 10, "n_jobs": 1} binary; multiclass	40/40
model:R27 回归 · DummyRegressor	以均值等固定策略输出目标；衡量复杂方法是否超越简单基线需另行有效评价。 {} continuous	20/20
model:R28 回归 · VotingRegressor	组合多个基学习器的投票或数值平均；不训练负责组合的第二层模型。 {"n_jobs": 1, "cv": 2, "members": ["R01", "R12"], "member_parameters": {"R12": {"max_depth": 3}}} continuous	20/20
model:R29 回归 · StackingRegressor	用基学习器的交叉验证输出训练第二层模型；区别于直接投票，需防止元学习泄漏。 {"n_jobs": 1, "cv": 2, "members": ["R01", "R12"], "member_parameters": {"R12": {"max_depth": 3}}} continuous	20/20
model:R30 回归 · BaggingRegressor	在重采样子集上拟合基学习器并聚合；区别于逐阶段纠正前序误差的提升。 {"n_estimators": 10, "n_jobs": 1} continuous	20/20
model:R31 回归 · BayesianRidge	在贝叶斯线性回归中估计共同权重精度和噪声精度；区别于固定惩罚的 Ridge。 {"max_iter": 10} continuous	20/20
model:R32 回归 · ARDRegression	为各特征估计独立精度并可剪除权重；比共同精度的 BayesianRidge 更具稀疏性。 {"max_iter": 10} continuous	20/20

方法	机制、配置与契约	PASS/预定
model:R33 回归 · KernelRidge	以核技巧求解 L2 正则最小二乘；与 SVR 的 epsilon 损失不同，通常不稀疏。 {} continuous	20/20
model:R34 回归 · RANSACRegressor	反复抽样识别内点后拟合；鲁棒性依赖残差阈值和足够的内点比例。 {"max_trials": 10, "min_samples": 0.5} continuous	20/20
model:R35 回归 · TheilSenRegressor	聚合子样本回归估计以获得鲁棒斜率；计算规模和高维鲁棒性有限制。 {"max_iter": 10, "n_jobs": 1} continuous	20/20
model:R36 回归 · PLSRegression	提取与目标协变的潜成分再回归；有监督，区别于只保留输入方差的 PCA。 {"max_iter": 10, "n_components": 2} continuous	20/20
model:K11 聚类 · GaussianMixture	以高斯混合分布拟合样本并提供软归属概率；簇形状受协方差结构制约。 {"max_iter": 10, "n_components": 2, "n_init": 1} unsupervised	20/20
model:K12 聚类 · BayesianGaussianMixture	以变分贝叶斯权重先验约束混合成分；可降低冗余成分权重。 {"max_iter": 10, "n_components": 2, "n_init": 1} unsupervised	20/20
model:K13 聚类 · HDBSCAN	基于密度层次提取稳定簇，可标记噪声；区别于固定 epsilon 的 DBSCAN，无原生新样本预测。 {"n_jobs": 1} unsupervised	20/20
model:D11 降维 · UMAP	构建模糊近邻图并优化低维图表示；与 t-SNE 目标不同，可支持已拟合映射的新样本变换。 {"n_epochs": 10, "n_components": 2, "n_neighbors": 3, "n_jobs": 1} unsupervised	20/20
model:D12 降维 · Autoencoder	通过瓶颈编码重建输入；非线性表示需训练，重建成功不证明保留研究相关信息。 {"max_epochs": 2, "n_components": 2, "batch_size": 16} unsupervised	20/20

方法	机制、配置与契约	PASS/预定
model:T01 回归 · NaiveForecast	朴素预测：未来均取训练末值；提供单变量固定起点基线，不学习周期。 {"max_iter": 10, "seasonal_period": 4, "order": [1, 0, 0], "seasonal_order": [1, 0, 0, 4]} forecast	20/20
model:T02 回归 · SeasonalNaiveForecast	季节朴素预测：重复训练末段季节周期；依赖正确给定周期，本次为 4。 {"max_iter": 10, "seasonal_period": 4, "order": [1, 0, 0], "seasonal_order": [1, 0, 0, 4]} forecast	20/20
model:T03 回归 · ExponentialSmoothing	指数平滑：对历史值递减加权估计水平；本次未设置趋势或季节项，不称为完整季节模型。 {"max_iter": 10, "seasonal_period": 4, "order": [1, 0, 0], "seasonal_order": [1, 0, 0, 4]} forecast	20/20
model:T04 回归 · ARIMA	ARIMA：结合自回归、差分与移动平均；本次(1,0,0)，无差分和 MA 项。 {"max_iter": 10, "seasonal_period": 4, "order": [1, 0, 0], "seasonal_order": [1, 0, 0, 4]} forecast	20/20
model:T05 回归 · SARIMA	SARIMA：在 ARIMA 上增加季节结构；本次非季节(1,0,0)、季节(1,0,0,4)。 {"max_iter": 10, "seasonal_period": 4, "order": [1, 0, 0], "seasonal_order": [1, 0, 0, 4]} forecast	20/20
model:N07 回归 · 1D CNN	一维 CNN：以局部时间卷积提取窗口模式；感受野由卷积结构决定。 {"hidden_size": 8, "num_layers": 1, "batch_size": 16, "max_epochs": 2, "patience": 1, "device": "cpu"} sequence	20/20
model:N08 回归 · TCN	TCN：采用因果/膨胀时间卷积建模窗口依赖；区别于递归逐步状态更新。 {"hidden_size": 8, "num_layers": 1, "batch_size": 16, "max_epochs": 2, "patience": 1, "device": "cpu"} sequence	20/20

方法	机制、配置与契约	PASS/预定
model:N09 回归 · Transformer	Transformer：以注意力组合窗口内信息；时间位置编码及掩码决定顺序/可见范围。 {"hidden_size": 8, "num_layers": 1, "batch_size": 16, "max_epochs": 2, "patience": 1, "device": "cpu"} sequence	20/20
model:H01 序列/HMM · GaussianHMM	Gaussian HMM：离散隐状态转移与单高斯发射；需明确每段序列长度。 {"n_components": 2, "n_iter": 10} hmm	14/20
model:H02 序列/HMM · GMMHMM	GMM HMM：每个隐状态使用高斯混合发射；比单高斯 HMM 增加状态内分布复杂度。 {"n_components": 2, "n_iter": 10, "n_mix": 2} hmm	20/20
model:H03 序列/HMM · CategoricalHMM	Categorical HMM：发射为离散符号概率；与连续高斯发射的数据契约不同。 {"n_components": 2, "n_iter": 10} hmm	20/20
model:N01 分类 · Sequential	Sequential 分类网络：前馈非线性映射输出类别；由本包模块与 skorch 封装组成。 {"hidden_size": 8, "num_layers": 1, "batch_size": 16, "max_epochs": 2, "patience": 1, "device": "cpu"} binary; multiclass	40/40
model:N02 回归 · Sequential	Sequential 回归网络：前馈映射输出连续目标；与 N01 的目标和损失契约不同。 {"hidden_size": 8, "num_layers": 1, "batch_size": 16, "max_epochs": 2, "patience": 1, "device": "cpu"} continuous	20/20
model:N04 序列回归 · LSTM module	LSTM：显式细胞状态及门控保留历史信息；以固定窗口作下一步回归，保留序列边界。 {"hidden_size": 8, "num_layers": 1, "batch_size": 16, "max_epochs": 2, "patience": 1, "device": "cpu"} sequence	20/20
model:N06 序列回归 · GRU module	GRU：用更新/重置门调节隐状态；与 LSTM 相比省去独立细胞状态。 {"hidden_size": 8, "num_layers": 1, "batch_size": 16, "max_epochs": 2, "patience": 1, "device": "cpu"} sequence	20/20

注。搜索和内部集成有额外拟合，不与外层槽位数混淆；各目标/表的完整配置与结果另附。

参数搜索

表 A2

参数搜索差异与状态

方法	机制、配置与契约	PASS/预定
search:grid grid	网格搜索：按离散候选组合枚举；本次只搜索 C 的两个预设取值。 {} binary; multiclass	40/40
search:random random	随机搜索：随机采样候选；覆盖依赖预算和采样分布，本次最多 2 次候选拟合。 {} binary; multiclass	40/40
search:genetic genetic	遗传搜索：通过种群选择、交叉和变异提出候选；两次拟合预算仅验证执行路径。 {} binary; multiclass	40/40
search:annealing annealing	退火搜索：温度控制接受较差候选的概率；本次 C 为[0.25,1.0]连续范围。 {} binary; multiclass	40/40
search:tpe tpe	TPE 搜索：利用较好/较差候选的参数密度提出新候选；极小预算不检验长期优化优势。 {} binary; multiclass	40/40

注。搜索和内部集成有额外拟合，不与外层槽位数混淆；各目标/表的完整配置与结果另附。

训练前降维

表 A3

训练前降维差异与状态

方法	机制、配置与契约	PASS/预定
reduction:pca pca	中心化后寻找最大方差正交方向；不使用目标标签，不等同于生理信号源分离。 本次作为 C01 训练前的二维转换，而非独立降维任务。 {} binary; multiclass	40/40

方法	机制、配置与契约	PASS/预定
reduction:truncated_svd truncated_svd	对未强制中心化的矩阵作截断奇异值分解；适合稀疏表示，区别于中心化 PCA。 本次作为 C01 训练前的二维转换，而非独立降维任务。 {} binary; multiclass	40/40
reduction:fast_ica fast_ica	通过非高斯性等准则寻找统计独立成分；独立性假设强于不相关性。 本次作为 C01 训练前的二维转换，而非独立降维任务。 {} binary; multiclass	40/40
reduction:gaussian_random_projection gaussian_random_projection	高斯随机投影：不按目标或方差优化方向，用随机矩阵压缩维度；区别于数据学习的 PCA。 本次作为 C01 训练前的二维转换，而非独立降维任务。 {} binary; multiclass	40/40
reduction:kernel_pca kernel_pca	在核空间提取主成分；非线性映射依赖核设置，默认核不一定非线性。 本次作为 C01 训练前的二维转换，而非独立降维任务。 {} binary; multiclass	40/40

注。搜索和内部集成有额外拟合，不与外层槽位数混淆；各目标/表的完整配置与结果另附。